

边缘计算中信任流驱动的可信联邦关键技术研究

TTFL: Trust-Flow-Driven Trusted Federated Learning for Edge Computing

匿名作者

摘要

联邦学习 (FL) 通过避免原始数据迁移来支持边缘智能协同训练, 但开放式边缘参与也使聚合过程暴露于不可信执行、模型投毒、隐蔽后门以及严重 Non-IID 偏移等风险之下。现有鲁棒聚合方法往往依赖更严格的阈值来拒绝恶意更新, 却容易同时剔除合法的长尾客户端。本文提出一种信任流驱动的可信联邦学习框架, 将硬件锚定准入、运行时信任证据、双流信誉演化和风险门控分层聚合联系起来。该方法通过历史性能流和瞬时风险流分离长期效用与短期攻击风险, 再利用按层门控、裁剪和幸存者权重重归一化, 在抑制投毒更新的同时保留有价值的异构贡献。基于 Flower/PyTorch 的 CIFAR-10 实验包含 20 个准入客户端、6 类混合攻击和 5 次重复运行; 结果表明, 在 30% 恶意设置下, 该方法达到 92.31% 的准确率和 10.21% 的 ASR, 永久封禁误杀率接近零。

关键词: 联邦学习; 边缘计算; 可信执行环境; 风险建模; 分层聚合; 后门防御

1 引言

联邦学习通过参数交换训练全局模型, 并将数据保留在边缘设备本地 [1, 2]。这一范式适合边缘智能场景, 但当客户端身份、执行完整性和更新语义无法完全可信时, 聚合阶段会变得脆弱。实际边缘网络还同时存在设备异构和强偏斜数据分布, 因此鲁棒聚合必须区分恶意偏移和合法长尾更新。在复合攻击下, 这一区分更加困难, 因为攻击者可能提交投毒参数、注入定向后门, 或利用跨轮伪装降低可见异常。

已有工作从不同角度处理这一问题。Krum 和 Trimmed Mean 等几何或统计防御会剔除离群更新 [3, 4]。FLTrust 和 FoolsGold 利用干净参考或时序相似性 [5, 6]; RaSA 与 FLDetector 则面向边缘辅助聚合和模型投毒检测 [7, 8]。面向后门的防御进一步考察深层行为、裁剪加噪或净化机制 [9, 10, 12]; 相关工作也考虑联邦后门检测、定向合谋和隐私保护投毒防御 [11, 13, 14]。这些机制仍面临两类反复出现的张力: 静态软件检查不能保证本地执行确实真实; 过强过滤又容易将 Non-IID 长尾更新误判为攻击。TEE 辅助联邦系统为训练完整性和 SGX 式分布式学习提供硬件信任根 [16, 18], 近期工作进一步研究隐私保护 FL、攻击缓解和恶意参与者下的可信训练 [15, 17, 19]。但客户端准入之后, TEE 本身并不能判断真实训练产生的模型更新是否在语义上安全。

本文提出 *Trust Flow*, 一个面向边缘联邦学习的全流程可信聚合框架。其核心思想是让信任证据在准入、审查、时序状态演化和聚合之间持续流动, 而不是把每一轮视作孤立的过滤决策。本文贡献如下:

1. 提出一种 TEE 锚定的动态准入机制, 将远程证明式准入证据与运行时行为熵、卡尔曼滤波结合起来。
2. 提出双流信誉模型, 将历史效用与瞬时攻击风险解耦, 以缓解恶意召回与永久误杀之间的冲突。
3. 提出按层风险门控聚合规则, 结合差异化准入阈值、动态 L2 裁剪和幸存者权重重归一化。
4. 在 Non-IID CIFAR-10 与混合攻击设置下完成端到端评估, 并补充压力测试与消融实验。

2 背景与相关工作

边缘计算中的联邦学习。标准 FL 工作流中, 客户端完成本地训练并向服务器提交参数更新, 服务器聚合后再分发全局模型。该流程保留了数据本地性, 却使服务器高度依赖上传更新的真实性和质量。边缘计算进一步增加了复杂度, 因为客户端的算力、通信稳定性和数据分布均存在差异。更开放、分层的系统也会扩大客户端准入、本地执行和更新聚合周围的攻击面。

投毒与后门攻击。FL 中的攻击主要包括无目标投毒和目标后门。符号翻转、梯度缩放等无目标投毒旨在破坏收敛; 标签翻转、触发器后门、干净标签投毒和语义后门则试图保持主任务行为, 同时植入定向误分类。后门攻击尤其棘手, 因为恶意更新可在方向上接近正常更新, 却改变隐藏特征 [20, 21]。在多层训练中, 攻击者还可能先正常行为以积累信任, 再注入低幅度或间歇式恶意更新。

主动防御及其局限。鲁棒聚合通常依赖几何距离、坐标级统计、干净锚点、时序相似性或自适应聚合。Krum 与 Trimmed Mean 拒绝或抑制离群更新 [3, 4]; FLTrust 使用服务器端干净参考方向 [5]; FoolsGold 和 FLDetector 利




图 1: TEE 锚定的端-边-云协同架构。

用历史或客户端行为识别恶意参与 [6, 8]; RaSA 在边缘辅助场景下调整安全聚合 [7]。后门防御方面, DeepSight 与 FLAME 检查隐藏行为或更新簇 [9, 10]; CrowdGuard 与 RoseAgg 处理联邦后门检测和定向合谋 [11, 13]; FLPurifier 与 ShieldFL 则从净化或隐私保护防御角度缓解投毒 [12, 14]。但这些防御对强 Non-IID 分布仍较敏感: 阈值严格会增加良性误杀, 阈值宽松则会放过隐蔽攻击。

TEE 辅助可信训练。Intel SGX 和 ARM TrustZone 等可信执行环境可提供隔离执行与受保护密钥材料。已有研究展示了 TEE 在训练完整性和 SGX 分布式学习中的价值 [16, 18], 也将其用于鲁棒隐私保护 FL 和攻击缓解 [15, 17], 以及恶意参与者下的可信模型训练 [19]。不过, TEE 准入不能单独判断一个真实训练过程生成的模型更新是否语义安全。因此, Trust Flow 将硬件根准入与跨轮风险建模、分层鲁棒聚合结合起来。

3 系统模型与威胁假设

系统包含中心服务器 S 与 K 个边缘客户端 $C = \{c_1, \dots, c_K\}$ 。第 t 轮中, 通过准入的客户端接收 $W^{(t-1)}$, 完成本地训练后上传 $\Delta W_k^{(t)}$, 服务器更新 $W^{(t)} = W^{(t-1)} + \text{Agg}(\{\Delta W_k^{(t)}\})$ 。全局目标为

$$\min_W \mathcal{L}(W) = \sum_{k=1}^K p_k \mathcal{L}_k(W), \quad p_k = |\mathcal{D}_k| / \sum_j |\mathcal{D}_j|. \quad (1)$$

边缘场景遵循端-边-云 workflow: 客户端侧负责本地训练和信任证据生成, 服务器侧负责更新审查、信任状态演化和安全聚合。

威胁模型。服务器是诚实但好奇的, 并按聚合协议执行。攻击者可控制已准入客户端, 并实施标签翻转、触发器后门、干净标签投毒、语义后门、符号翻转和梯度缩放。本文假设恶意客户端比例上界为 $< 50\%$ 。主实验采用 30% 作为典型高风险设置, 并额外报告 50% 边界压力测试。TEE 被假定能够在宿主操作系统被攻陷时保护证明关键代码和密钥, 但不考虑物理探测和高级微架构侧信道攻击。

设计目标。Trust Flow 旨在: (i) 在混合投毒和后门攻击下保持收敛; (ii) 使合法长尾客户端的永久封禁误杀率 (FPR) 保持较低; (iii) 避免重型密码学开销, 同时保持边缘可部署性。图 1 和图 2 分别概括物理工作流与威胁面。

这些目标相互耦合。纯过滤策略中, 增强拒绝规则可以提高恶意召回, 却会同时剔除本地分布偏离多数方向的良性客户端; 放宽规则能保护长尾客户端, 却会让低幅度投毒持续存在。Trust Flow 将该问题视为状态分离问题, 而不是简单阈值调参: 准入证据、内容质量、历史贡献和瞬时风险在最终分层聚合决策之前始终保持为不同信号。

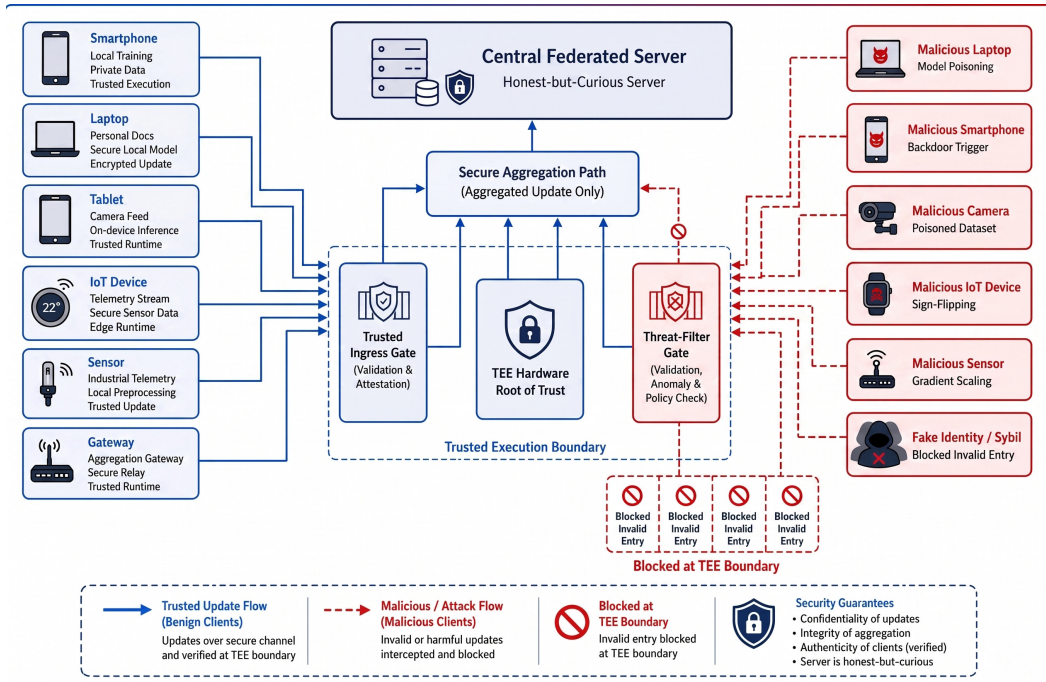


图 2: 复合投毒与渗透威胁模型。

4 Trust-Flow 框架

Trust Flow 将每一轮 FL 划分为四个相互连接的阶段：准入与运行时信任评估、基于参考的内容审查、双流状态演化以及风险门控分层聚合。图 3 展示了完整防御闭环。

从更高层看，该框架是一条信任状态转移管线。第一阶段输出 *TrustScore*，刻画客户端是否具有可信参与基础；第二阶段输出 *ContentScore*，衡量当前更新是否与干净参考和群体方向一致；第三阶段将这些信号沉淀为 *HistPerf* 与 *RiskEMA*，分离长期贡献和短时异常；第四阶段将状态融合为 *RawScore* 并执行差异化分层聚合。这一设计避免把某一轮低分直接视为恶意证据，这对强 Non-IID 数据下的长尾客户端尤其重要。

从操作流程看，每一轮都遵循相同的决策路径。服务器先移除未通过准入证明的客户端，因为这些更新无法绑定到受保护执行路径；随后对剩余更新计算其相对于干净参考和可信群体的质量，但该分数仍只是临时证据。临时证据会被沉淀到慢速效用状态和快速风险状态中，最后才转化为按层聚合权限。这样的顺序是有意设计的：前置阶段回答证据是否可信，中间阶段判断当前更新是有用还是有风险，最终阶段再决定该更新能在哪些网络层参与贡献。因此，框架避免在每轮开始时设置单一硬门槛，从而降低强 Non-IID 下的脆弱性，同时在风险证据持续存在时仍能执行硬隔离。

4.1 准入与内容审查

每个准入客户端都必须通过 TEE 式准入检查。令 $M_{\text{attest},k} \in \{0,1\}$ 表示证明报告是否有效。初始化期间，客户端调用设备唯一密钥并生成远程证明 quote，其中包含 PCR 链、代码段签名和运行配置等完整性测量。只有通过该检查的客户端才获得通信权限。本地训练期间，可信管理代理监测行为序列 $\mathcal{X}_k = \{\Delta\text{grad}, \Delta\text{loss}, \text{instr_dist}\}$ 。其熵 $H(\mathcal{X}_k) = -\sum_i p(x_i) \log p(x_i)$ 被映射为测量不确定性 $R_k^{(t)} = \exp(\lambda H(\mathcal{X}_k^{(t)}))$ 。直观地看，若某个客户端的本地训练突然呈现高熵状态，它未必已经恶意，但本轮证据的可信度应低于稳定执行下产生的证据。

依据鲁棒滤波思想，信任估计按下式更新：

$$\hat{T}_k^{(t)} = \hat{T}_k^{(t-1)} + K_k^{(t)}(Z_k^{(t)} - \hat{T}_k^{(t-1)}), \quad \text{TrustScore}_k = \hat{T}_k^{(t)}(1 + P_k^{(t)})^{-1}. \quad (2)$$

高熵运行行为因此会降低卡尔曼增益，防止突发异常观测被吸收到长期信任估计中。协方差 $P_k^{(t)}$ 作为置信边界：协方差越小，信任估计越可靠。因此，准入结果不是一次性二元决策，而是可持续更新的权限因子，并可传递到后续审查与聚合阶段。

随后，服务器构造干净指导方向。若存在小型干净验证梯度，则 $g_{\text{root}} = g_{\text{root_clean}}$ ；否则，使用高信任且上




图 3: 五阶段信任流防御闭环概览。

一轮风险较低的客户端，并以 $\omega_k^{ref} = TrustScore_k(1 - RiskEMA_k^{prev})^2$ 作为参考权重。该退化参考在边缘部署中很重要：服务器侧干净集可能很小甚至不存在，此时参考方向应保持保守，但不能被近期可疑客户端主导。对每个客户端更新，内容质量由参考一致性和群体一致性共同构成：

$$S_{contrib,k} = \max(0, \alpha_1 + \alpha_2 \cos(\Delta W_k, g_{root})), \quad (3)$$

$$S_{consist,k} = \frac{\sum_{j \neq k} TrustScore_j \max(0, \alpha_1 + \alpha_2 \cos(\Delta W_k, \Delta W_j))}{\sum_{j \neq k} TrustScore_j + \epsilon}, \quad (4)$$

$$ContentScore_k = \frac{(1 + \beta_{fusion}^2) S_{consist,k} S_{contrib,k}}{\beta_{fusion}^2 S_{consist,k} + S_{contrib,k} + \epsilon}. \quad (5)$$

其中 $\beta_{fusion} > 1$ 会提高干净方向的影响，有助于抵抗合谋漂移。这里采用调和式融合并非只为数值平滑，而是要求客户端同时干净参考和可信群体两个方向上都具有合理性。仅有较高群体一致性不足以抵抗合谋，只有较高参考一致性又可能过度惩罚合法 Non-IID 更新。

4.2 双流状态演化

单一信誉分会混淆由数据偏斜导致的低效用和由攻击导致的高风险。Trust Flow 因此将客户端状态分为历史效用流和瞬时风险流。历史流将归一化后的内容质量视为 Beta 信誉模型中的软证据：正向证据增加 α_k ，弱证据增加 β_k ，二者均带有衰减系数 λ_h ；历史效用期望为 $HistPerf_k^{(t)} = \alpha_k^{(t)} / (\alpha_k^{(t)} + \beta_k^{(t)} + \epsilon)$ 。

该通道刻意保持缓慢。合法长尾节点可能因为本地数据分布不同于多数客户端而在若干轮中获得较低内容分，这不应被立即解释为攻击。较低 $HistPerf$ 因此只会降低聚合权限或触发临时软隔离，而不是永久移除。风险流的作用正好相反：它对报告异常、梯度方向与幅度、小型干净集损失上升、触发器激活漂移、符号不一致和群体分歧等探针取最大值，并按 $RiskEMA_k^{(t)} = \beta_r RiskEMA_k^{(t-1)} + (1 - \beta_r) Risk_k^{inst}$ 更新。这样，单次强攻击信号不会被历史良性行为平均掉。

这种分离还改变了边界客户端的处置方式。若某个客户端内容质量偏弱但风险没有上升，系统会保留其参与资格并降低影响力，让后续轮次继续判断低分是否由 Non-IID 漂移造成。若某个客户端历史效用尚可但瞬时风险突然升高，则当前更新会在进入敏感层之前被降权或阻断。这种非对称响应是实验中永久误封率较低的关键，因为框架不再要求同一个阈值同时承担质量筛选和攻击检测两种任务。

这两个流只在计算聚合限时汇合：

$$RawScore_k = (TrustScore_k)^\alpha (ContentScore_k)^\beta (HistPerf_k^{(t-1)})^\gamma \times (1 - RiskEMA_k^{(t-1)})^p. \quad (6)$$

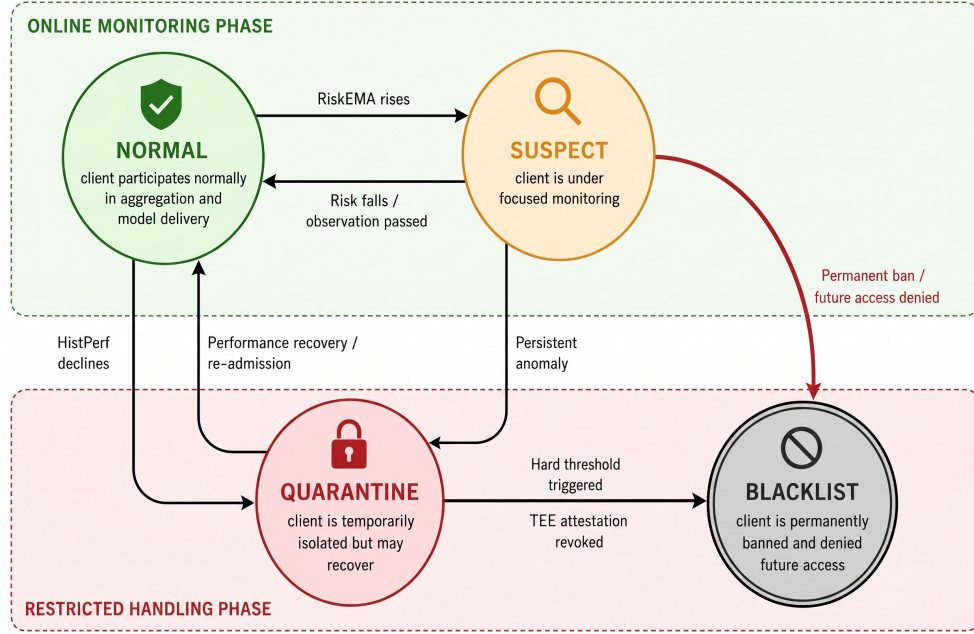


图 4: 由历史效用和瞬时风险驱动的客户状态转移自动机。

乘法形式使最终权限保持保守：客户端需要同时具有足够的执行可信度、当轮内容质量、历史效用和较低近期风险。最终状态机区分 NORMAL、SUSPECT、QUARANTINE 与 BLACKLIST，如图 4 所示。潜伏-爆发型攻击者可在早期良性轮次积累较高 $HistPerf$ ，但后续触发注入会激活触发器或干净探针通道并提高 $RiskEMA$ ，从而在历史效用较高时仍被阻断。相反，当前相似性较低的长尾良性客户端主要由缓慢效用流处理，并可在后续正向贡献后恢复。

4.3 风险门控分层聚合

后门往往集中在深层，而浅层特征层可能携带有价值的异构信息。Trust Flow 因此为每个层 l 分配敏感度分数：该分数融合三类信号：隐私暴露、参考梯度效用和安全偏离。隐私项随深度衰减，效用项度量该层参考梯度范数的相对大小，安全项度量可信客户端更新相对参考方向的漂移程度。三者加权得到 $S_{total}^{(l)}$ ，并同时控制层准入阈值 $\theta^{(l)} = \mu_{base} + \lambda_s S_{total}^{(l)}$ 与裁剪半径 $C^{(l)} = C_{base} / (S_{total}^{(l)} + \varepsilon_c)$ 。因此，若某层出现更强可疑漂移，该层会变得更难进入且裁剪更紧；若某层仍稳定接近参考方向，则保留更多良性异构容量。

幸存者集合为 $\Phi^{(l)} = \{k \in \mathcal{A} \mid RawScore_k \geq \theta^{(l)}\}$ ，其权重重新归一化为

$$\tilde{w}_k^{(l)} = \frac{RawScore_k}{\sum_{j \in \Phi^{(l)}} RawScore_j + \varepsilon}, \quad \widehat{\Delta W}_k^{(l)} = \frac{\Delta W_k^{(l)}}{\max(1, \|\Delta W_k^{(l)}\|_2 / C^{(l)})}. \quad (7)$$

最终更新为 $\Delta W_{global}^{(l)} = \sum_{k \in \Phi^{(l)}} \tilde{w}_k^{(l)} \widehat{\Delta W}_k^{(l)}$ 。权重重新归一化可以防止剔除风险客户端后有效学习率缩小。

这种按层控制旨在保留有用的浅层表征，同时加固攻击敏感度更高的层。以语义后门为例，攻击通常更集中地改变最终分类层或深层特征层；统一全局裁剪要么足够宽松以保留浅层特征，要么足够严格以压制深层攻击，却很难兼顾二者。Trust Flow 允许不同层在同一轮采用不同策略：深层可以拒绝低权限客户端并收紧更新半径，浅层在参考一致性稳定时仍可保持较宽松阈值。这种差异化处理很重要，因为统一裁剪半径会过度压制良性特征提取层，并在恶意客户端已被移出幸存集后拖慢收敛。

重归一化步骤对收敛同样关键。若没有该步骤，剔除可疑客户端会降低有效聚合权重之和，并形成隐式学习率衰减。这种衰减容易被误认为是鲁棒性控制带来的正常副作用，但在固定 30 轮训练预算下会直接拖慢优化。Trust Flow 因此将过滤与优化视为耦合操作：移除不安全权重后，剩余可信权重会先被投影回有效聚合单纯形，再进入裁剪和分层组装。




图 5: 风险门控的按层裁剪与差异化聚合。

4.4 分析视角

双流结构为解释 FPR/ASR 权衡提供了一个简单视角。设合法长尾客户端的单轮内容服从期望为 μ_{clean} 、方差为 σ_{clean}^2 的扰动分布。刚性阈值会在当前分数低于阈值时剔除该客户端，即便偏差来自 Non-IID 数据。经过指数平滑后，历史效用估计的稳态方差遵循标准低通形式：

$$\text{Var}(\text{HistPerf}_k^{(\infty)}) = \frac{1 - \beta_h}{1 + \beta_h} \sigma_{clean}^2. \quad (8)$$

当 β_h 接近 1 时，短期良性波动被抑制，客户端更不容易遭到持续移除。相比之下，瞬时风险流会响应攻击冲击。若某个后门轮次产生异常探针值，最大算子会防止该事件在进入 EMA 前被平均掉。因此，将长期贡献和短期风险放在不同空间处理，可以减少单分数冲突：长尾更新被平滑而非立即封禁，突发恶意信号则保留足够强度以触发隔离。

4.5 风险探针计算

瞬时风险流使用的探针彼此冗余，而不是各自单独作出最终裁决。梯度探针同时度量相对 g_{root} 的方向偏离和相对本轮统计量的异常幅度，因此适合捕获符号翻转和梯度缩放，但对梯度方向接近良性的干净标签攻击并不充分。干净探针会将候选更新应用到服务器侧小型探针集，并记录交叉熵损失的上升。触发器探针通过 KL 散度比较高层激活直方图， $r_{trigger,k}^{(t)} = \text{KL}(\mathcal{H}(A_{base}) \parallel \mathcal{H}(A_k))$ ，因而更敏感于语义后门或干净标签后门造成的特征层漂移。

这些探针通过最大值规则融合，是因为它们的失效模式不同。高幅度攻击者通常会先被梯度通道暴露，而隐蔽后门可能只表现为较小的干净损失变化，却伴随明显激活偏移。风险流保留本轮最强警告，使不同攻击家族都能被状态机看到，而不需要依赖一个统一的异常分数。

这些探针在审查中还具有诊断作用。若梯度通道占主导，服务器会将该客户端视为优化层面的威胁，并主要通过裁剪和层阈值抑制其影响；若干净探针或触发器通道占主导，则该更新在数值上可能看似普通，但语义上并不安全，因此即使历史效用较高，状态机也会推动该客户端进入隔离观察。群体分歧只作为辅助证据，而不是单独移除的理由，因为合法长尾客户端也可能与多数方向不一致。这种诊断分离降低了防御对单一分数校准的依赖，也解释了为何同一管线能够同时处理显式参数攻击、干净标签漂移和语义后门。

表 1: 紧凑实验配置与主要超参数。

类别	设置	取值
FL 任务	数据集/模型/准入客户端	CIFAR-10/轻量 CNN/ $K = 20$
优化	本地 epoch、学习率、动量、轮次	3, 0.001, 0.9, 30
数据异构	共享池、Group A、Group B/C	5000, $\alpha = 1.0$, $\alpha = 0.1$
信任流	$\alpha_1, \alpha_2, \beta_{fusion}; \beta_h, \beta_r$	0.6, 0.4, 2.0; 0.9, 0.85
分层门控	融合指数; μ_{base}, λ_s	3.0, 1.0, 0.5, 1.0; 0.4, 1.2

5 实验

5.1 实验设置

实验使用 Flower 1.5.0 与 PyTorch，在 CIFAR-10 上训练轻量级 CNN。仿真部署在一台 Inspur 服务器上，硬件为双路 CPU 和五块 NVIDIA A10 GPU，软件栈为 Ubuntu 20.04.6 LTS 与 CUDA 12.8。为支持可复现性，完整日志、源代码和启动脚本均予以保留。50000 张训练图像划分给 20 个准入客户端。一个 5000 样本的类别均衡共享池提供共同对齐基础；客户端 6–11 遵循 Dirichlet $\alpha = 1.0$ ，客户端 12–19 使用强长尾划分 $\alpha = 0.1$ 。

正式 30% 攻击设置包含六个恶意客户端：Client 0 执行 $\gamma = 0.5$ 的标签翻转；Client 1 在 20% 样本中注入触发器后门并以类别 0 为目标；Client 2 使用干净标签后门扰动；Client 3 使用语义后门偏置；Client 4 执行符号翻转；Client 5 将更新放大 100 倍。另有五个无有效证书的 Sybil 节点和三个伪造低工作负载的 free-rider 节点用于验证第一阶段门控。这八个节点在统计分析前被拦截，因此后续指标均在 20 个准入客户端上计算。每次运行包含 30 轮和 3 个本地 epoch。Acc/ASR 聚合值取五个随机种子的平均；状态轨迹来自一个代表性种子。

准确率和 ASR 报告为五次独立运行的均值与标准差。永久封禁 FPR 以被不可逆列入黑名单的良性客户端计算，临时 SUSPECT 或 QUARANTINE 状态被视为可恢复控制动作。单次运行轨迹图采用固定种子，以便展示节点级转移；聚合表格使用重复运行结果。所有基线采用相同节点划分、攻击比例、优化器配置、通信轮次和 Non-IID 划分。

5.2 整体防御性能

图 6 总结了收敛、ASR、信任状态轨迹和特征分离结果。在 30% 混合攻击下，Trust Flow 收敛到 92.31% 准确率，并将 ASR 降至 10.21%，接近 CIFAR-10 的随机猜测基线。客户端状态追踪显示，显式投毒与参数攻击会被早期阻断，而更隐蔽的干净标签漂移则在持续探针证据出现后被捕获。合法长尾节点可能暂时进入 SUSPECT 或 QUARANTINE，但其风险流不会积累足够证据导致永久封禁。

节点轨迹揭示了不同决策路径。标签翻转和触发器后门客户端表现出持续较高的 r_{grad} 与 r_{probe} ，并在第 8 轮前进入黑名单。语义后门先引发软隔离，随后在持续风险积累后被移除。干净标签攻击更难检测，因为其本地损失表现正常；该攻击在漂移组合规则连续数轮保持激活后被识别。符号翻转显著降低方向贡献分，梯度缩放则由幅度探针和按层裁剪捕获。相比之下，长尾良性客户端早期可能内容质量偏低，但风险流并不持续上升，因此可通过后续 *HistPerf* 更新恢复。

t-SNE 可视化提供了补充视角。信任流介入前，恶意客户端和合法长尾客户端可能处在重叠区域，因为二者都可能偏离多数方向。双流监督后，恶意客户端形成与高风险探针相关的可分离簇，而合法长尾客户端仍与主要聚合区域保持连接。这支持了本文的设计主张：历史效用和瞬时风险不应过早压缩为一个分数。

与 FedAvg 相比，鲁棒聚合基线能够降低 ASR，但往往损失大量准确率或移除许多良性长尾客户端。Krum 将 ASR 降至 12.15%，但其距离规则排除了大量合法长尾更新，导致准确率仅为 64.20%。Trimmed Mean 在部分轮次比 Krum 更稳定，但坐标截断不足以抑制定向后门。FLTrust 受益于干净锚点，但当合法 Non-IID 更新偏离锚点时仍易受影响。Trust Flow 通过历史平滑保留良性异构贡献，同时用瞬时风险流阻止高信誉攻击者利用历史行为。50% 结果显示，该框架在理论边界附近仍保持稳定，达到 91.81% 准确率和 10.46% ASR。




图 6: 混合攻击下的主要防御行为。

表 2: 30% 混合攻击与边界压力测试下的性能比较。

方法/设置	核心机制	Acc.	ASR	Perm. FPR
FedAvg [2]	无防御	86.15 $\pm$ 1.20	92.34 $\pm$ 5.10	N/A
Krum [3]	欧氏选择	64.20 $\pm$ 2.80	12.15 $\pm$ 0.90	64.20
Trimmed Mean [4]	坐标截断	71.35 $\pm$ 2.40	38.60 $\pm$ 4.20	N/A
FLTrust [5]	干净锚点加权	81.25 $\pm$ 1.50	15.42 $\pm$ 1.10	21.40
Trust Flow	双流 + 分层门控	92.31 $\pm$ 0.09	10.21 $\pm$ 0.05	0.00
边界压力: 50% 恶意	10/20 恶意	91.81 $\pm$ 0.10	10.46 $\pm$ 0.06	0.00

FPR 表示良性客户端的不可逆误封。临时 SUSPECT/QUARANTINE 状态是可恢复控制动作，并通过轨迹单独呈现。

5.3 消融、敏感性与开销

表 3 表明，单流信誉模型面临 FPR/TPR 权衡：激进阈值增加误封，保守阈值漏检潜伏攻击。仅使用 Hist-Perf 可以保护良性节点，却缺少短期攻击敏感性。双流设计在保持永久误封较低的同时获得较高召回。开销适中：TrustReport 每次上传约增加 15 KB，服务器聚合时间从每轮 2.10 s 增至 4.85 s。

表 3 中 FPR/TPR 采用最终封禁口径。若将 SUSPECT 计为可逆风险复核状态，则恶意客户端逐轮覆盖率为 88.33%，正常客户端复核触发率为 14.79%，且不构成永久误杀。

图 7 和图 8 进一步分解了风险探针、权重重归一化和数据异构性的影响。干净参考结合浅层探针能够处理符号翻转和梯度缩放，但在梯度方向与良性更新共线时，干净标签后门仍较难识别。加入交叉熵与高层激活探针后，干净标签 ASR 降至 9.2% 以下。重归一化同样重要：没有幸存者权重修正的分层门控会产生隐式学习率衰减，而完整 Trust Flow 能在 30 轮预算内收敛。在 Dirichlet $\alpha = 0.1$ 下，Krum 与 FLTrust 明显退化，而 Trust Flow 仍保持接近 92% 的准确率。

敏感性曲线显示，当数据接近 IID 时，传统鲁棒聚合表现较好；但随着 α 降低，其性能会下降。在 $\alpha = 100$ 或 $\alpha = 1.0$ 时，Krum 和 FLTrust 与本文方法较接近；在长尾设置 $\alpha = 0.1$ 下，它们的过滤规则越来越容易将合法漂移视为恶意偏移。Trust Flow 对这种变化较不敏感，因为内容证据并不单独使用，而是与历史效用和瞬时风险共同整合。融合参数 β_{fusion} 控制干净参考支配群体一致性的强度。较小取值会保留更多长尾客户端但提高 ASR，较大取值会增强攻击抑制但可能过度惩罚异构更新。默认 $\beta_{fusion} = 2.0$ 在观察结果中取得最好的 Acc/ASR 平衡。

开销分析显示，Trust Flow 主要将成本转移到服务器侧。边缘侧附加约 15 KB 的 TrustReport，并执行轻量运行监测。服务器执行参考构建、成对一致性审查、双流更新和按层裁剪，使聚合时间从测试环境中的 2.10 s 增

表 3: 消融与开销概要。

研究项	变体/架构	FPR 或开销	TPR / 时间
信誉	单流 EMA, 激进	18.25% FPR	95.12% TPR
信誉	单流 EMA, 保守	2.10% FPR	48.33% TPR
信誉	HistPerf-only	0.15% FPR	21.05% TPR
信誉	双流 Trust Flow	0.00% FPR	100.00% TPR
开销	标准 FedAvg	额外 0 KB	2.10 s 聚合
开销	Trust Flow	~15 KB TrustReport	4.85 s 含审查




图 7: 风险探针与重归一化的组件级消融。

至 4.85 s。由于广域边缘 FL 轮次通常在通信和同步上的时间远大于聚合计算，该增量对目标场景仍是可接受的。

6 讨论与结论

Trust Flow 将准入证据、内容审查、时序信誉和按层聚合整合为一条统一的信任状态管线。其主要收益不仅是更强的攻击抑制，还在于更清晰地区分两类低更新相似性的来源：良性长尾数据和恶意操纵。这一区分使方法能够在混合攻击下保持较高召回，同时让永久封禁 FPR 接近零。

本文仍存在若干局限。由于多种新兴 TEE-FL 方法尚无公开可复现实现，本研究未能在相同实验设置下将其纳入直接基线。当前探针设计也主要针对视觉分类，尤其是 CIFAR-10 后门行为。后续工作将随最终稿发布源代码和实验脚本，以支持复现，评估更大规模边缘部署，并将多维风险探针扩展到 NLP 与联邦微调场景。

致谢

本研究得到国家自然科学基金项目 (No. 62002261) 和天津市自然科学基金项目 (No. 25JCQNJC00600) 的支持。

参考文献

[1] Kairouz, P., McMahan, H.B., Avent, B., et al.: Advances and open problems in federated learning. Foundations and Trends in Machine Learning 14(1–2), 1–210 (2021). <https://doi.org/10.1561/22000000083>

[2] McMahan, B., Moore, E., Ramage, D., Hampson, S., Agueria y Arcas, B.: Communication-efficient learning of deep networks from decentralized data. In: Proceedings of the 20th International Conference on Artificial Intelligence and Statistics, PMLR 54, pp. 1273–1282 (2017). <https://proceedings.mlr.press/v54/mcmahan17a.html>

[3] Blanchard, P., El Mhamdi, E.M., Guerraoui, R., Stainer, J.: Machine learning with adversaries: Byzantine tolerant gradient descent. In: Advances in Neural Information Processing Systems 30 (2017). [NeurIPS paper page](#)




图 8: 不同数据异构度下的鲁棒性压力测试。

- [4] Yin, D., Chen, Y., Ramchandran, K., Bartlett, P.: Byzantine-robust distributed learning: Towards optimal statistical rates. In: Proceedings of the 35th International Conference on Machine Learning, PMLR 80, pp. 5650–5659 (2018). <https://proceedings.mlr.press/v80/yin18a.html>
- [5] Cao, X., Fang, M., Liu, J., Gong, N.Z.: FLTrust: Byzantine-robust federated learning via trust bootstrapping. In: Proceedings 2021 Network and Distributed System Security Symposium (NDSS) (2021). <https://doi.org/10.14722/ndss.2021.24434>
- [6] Fung, C., Yoon, C.J.M., Beschastnikh, I.: The limitations of federated learning in Sybil settings. In: 23rd International Symposium on Research in Attacks, Intrusions and Defenses (RAID 2020), pp. 301–316. USENIX Association (2020). <https://www.usenix.org/conference/raid2020/presentation/fung>
- [7] Wang, L., Huang, M., Zhang, Z., Li, M., Wang, J., Gai, K.: RaSA: Robust and adaptive secure aggregation for edge-assisted hierarchical federated learning. IEEE Transactions on Information Forensics and Security 20, 4280–4295 (2025). <https://doi.org/10.1109/TIFS.2025.3559411>
- [8] Zhang, Z., Cao, X., Jia, J., Gong, N.Z.: FLDetector: Defending federated learning against model poisoning attacks via detecting malicious clients. In: Proceedings of the 28th ACM SIGKDD Conference on Knowledge Discovery and Data Mining, pp. 2545–2555 (2022). <https://doi.org/10.1145/3534678.3539231>
- [9] Rieger, P., Nguyen, T.D., Miettinen, M., Sadeghi, A.R.: DeepSight: Mitigating backdoor attacks in federated learning through deep model inspection. In: Network and Distributed System Security Symposium (NDSS) (2022). <https://doi.org/10.14722/ndss.2022.23156>
- [10] Nguyen, T.D., Rieger, P., Chen, H., et al.: FLAME: Taming backdoors in federated learning. In: 31st USENIX Security Symposium, pp. 1415–1432 (2022). <https://www.usenix.org/conference/usenixsecurity22/presentation/nguyen>
- [11] Rieger, P., Krauß, T., Miettinen, M., Dmitrienko, A., Sadeghi, A.R.: CrowdGuard: Federated backdoor detection in federated learning. In: Network and Distributed System Security Symposium (NDSS) (2024). <https://doi.org/10.14722/ndss.2024.23233>
- [12] Zhang, J., Zhu, C., Sun, X., Ge, C., Chen, B., Susilo, W., Yu, S.: FLPurifier: Backdoor defense in federated learning via decoupled contrastive training. IEEE Transactions on Information Forensics and Security 19, 4752–4766 (2024). <https://doi.org/10.1109/TIFS.2024.3384846>
- [13] Yang, H., Xi, W., Shen, Y., Wu, C., Zhao, J.: RoseAgg: Robust defense against targeted collusion attacks in federated learning. IEEE Transactions on Information Forensics and Security 19, 2951–2966 (2024). <https://doi.org/10.1109/TIFS.2024.3352415>

- [14] Ma, Z., Ma, J., Miao, Y., Li, Y., Deng, R.H.: ShieldFL: Mitigating model poisoning attacks in privacy-preserving federated learning. *IEEE Transactions on Information Forensics and Security* 17, 1639–1654 (2022). <https://doi.org/10.1109/TIFS.2022.3169918>
- [15] Zhang, X., Chen, Z., Chen, G., Feng, X., Shen, Q., Wu, Z.: RPPFL: Robust and privacy-preserving federated learning via trusted execution environments. In: *ICASSP 2025 - 2025 IEEE International Conference on Acoustics, Speech and Signal Processing*, pp. 1–5 (2025). <https://doi.org/10.1109/ICASSP49660.2025.10889398>
- [16] Chen, Y., Luo, F., Li, T., Xiang, T., Liu, Z., Li, J.: A training-integrity privacy-preserving federated learning scheme with trusted execution environment. *Information Sciences* 522, 69–79 (2020). <https://doi.org/10.1016/j.ins.2020.02.037>
- [17] Queyruet, S., Schiavoni, V., Felber, P.: Mitigating adversarial attacks in federated learning with trusted execution environments. In: *2023 IEEE 43rd International Conference on Distributed Computing Systems (ICDCS)*, pp. 626–637 (2023). <https://doi.org/10.1109/ICDCS57875.2023.00069>
- [18] Xu, T., Zhu, K., Andrzejak, A., Zhang, L.: Distributed learning in trusted execution environment: A case study of federated learning in SGX. In: *2021 7th IEEE International Conference on Network Intelligence and Digital Content (IC-NIDC)*, pp. 450–454 (2021). <https://doi.org/10.1109/IC-NIDC54101.2021.9660433>
- [19] Lu, Z., Wang, L., Zhang, Z., Huang, M., Wang, J., Li, M.: TMT-FL: Enabling trustworthy model training of federated learning with malicious participants. *IEEE Transactions on Dependable and Secure Computing* 22(3), 2723–2740 (2025). <https://doi.org/10.1109/TDSC.2024.3521377>
- [20] Bagdasaryan, E., Veit, A., Hua, Y., Estrin, D., Shmatikov, V.: How To Backdoor Federated Learning. In: *Proceedings of the Twenty Third International Conference on Artificial Intelligence and Statistics*, PMLR 108, pp. 2938–2948 (2020). <https://proceedings.mlr.press/v108/bagdasaryan20a.html>
- [21] Wang, B., Yao, Y., Shan, S., Li, H., Viswanath, B., Zheng, H., Zhao, B.Y.: Neural Cleanse: Identifying and mitigating backdoor attacks in neural networks. In: *2019 IEEE Symposium on Security and Privacy (SP)*, pp. 707–723 (2019). <https://doi.org/10.1109/SP.2019.00031>