

Trust Flow-Driven Trusted Federated Learning in Edge Computing: A Study on Key Technologies

边缘计算中信任流驱动的可信联邦关键技术研究

周家凯

2026 年 3 月

摘要

近年来，联邦学习凭借“数据不出本地、仅交换模型参数”的训练范式，为隐私约束下的多方协同建模提供了有效路径，已成为边缘智能的重要支撑。然而，在开放的边缘计算环境中，非独立同分布（Non-IID）数据、终端设备异构性与不可信客户端等因素叠加，使现有鲁棒聚合方法在安全性、鲁棒性与泛化能力之间面临显著权衡。为此，本文从软硬件协同角度提出一种基于全流程信任流的可信联邦聚合机制。首先，融合基于可信执行环境（TEE）的远程证明与运行时监测，在本地模型训练阶段实现客户端强制准入与执行完整性验证；其次，针对潜伏攻击的跨轮识别问题，设计双流正交信誉演化方法，将客户端信任状态分解为表征长期贡献的历史效用流和表征短期异常的瞬时风险流，实现长期稳定性与快速风险熔断的协同；最后，提出基于纯净参考方向的分层差异化聚合策略，通过按层门控、权重重归一化和动态裁剪，在抑制恶意更新传播的同时保留合法异构贡献，缓解 Non-IID 条件下模型泛化能力下降问题。基于 Flower 平台在 CIFAR-10 数据集上的 20 客户端、6 类混合攻击实验结果表明，本文机制在保证模型精度达到 92.31%($\pm 0.09\%$) 的同时，将后门攻击成功率 (ASR) 控制在 10.21%($\pm 0.05\%$)，且正常客户端的永久误杀率趋近于 0。

关键词：联邦学习；边缘计算；可信执行环境；风险状态建模；分层鲁棒聚合；后门防御

Abstract

In recent years, federated learning has become a key enabler of edge intelligence by supporting collaborative model optimization under privacy constraints through the paradigm of keeping data local and exchanging only model parameters. However, in open edge-computing environments, the combined effects of non-independent and identically distributed (Non-IID) data, device heterogeneity, and untrusted clients expose significant tradeoffs among security, robustness, and generalization for existing robust aggregation methods. To address this issue, we propose a trusted federated aggregation mechanism based on end-to-end trust flow from a hardware-software co-design perspective. First, remote attestation and runtime monitoring based on trusted execution environments (TEEs) are integrated to enforce client admission and verify execution integrity during local training. Second, to identify stealthy attacks across training rounds, we design an orthogonal dual-stream reputation evolution method that decomposes client trust state into a historical utility stream for long-term contribution and an instant risk stream for short-term anomalous behavior, enabling coordinated long-term stability and rapid risk cut-off. Third, we propose a layer-wise differentiated aggregation strategy guided by a clean reference direction. By combining layer-wise gating, weight re-normalization, and dynamic clipping, the method suppresses malicious updates while preserving legitimate heterogeneous contributions, thereby mitigating the degradation of

generalization under Non-IID settings. Experiments on Flower with CIFAR-10 under 20 clients and six mixed attack types show that the proposed mechanism achieves an average accuracy of 92.31% ($\pm 0.09\%$) while limiting the attack success rate (ASR) to 10.21% ($\pm 0.05\%$), with the permanent false positive rate on benign clients approaching zero.

1 引言

联邦学习 (Federated Learning, FL) 通过“数据不出本地、仅交换模型参数”的机制, 在保护数据隐私的同时实现多方协同建模 [1]。该模式已成为边缘智能的重要基础能力, 并在工业物联网、医疗诊断等场景中得到广泛应用。随着 FL 从实验环境走向开放网络, 系统性能不再仅由模型结构与优化器决定, 聚合阶段的可信性与稳健性日益成为影响整体可用性的关键因素。究其原因在于: 边缘端数据天然分布异构、设备能力具有显著的差异、参与方行为难以完全约束, 这些特征在云端聚合时会显著放大统计偏移与安全风险。

在标准 FL 流程中, 客户端在本地完成训练并上传更新参数, 服务器执行聚合参数后下发新模型, 训练通过多轮迭代达到收敛, 但是该训练流程在真实边缘计算环境中面临三重安全风险。首先, Non-IID 数据会增加最优更新的方向离散度, 使“正常波动”与“异常偏移”的边界变得不清晰。其次, 攻击者可实施参数投毒与隐蔽后门等攻击 (如干净标签污染、语义后门) [2, 3], 并将恶意触发特征嵌入常规更新分布参数, 降低单轮检测成功率。最后, 由于开放执行环境缺少强制完整性约束, 客户端可能绕过真实训练过程直接构造上报训练参数, 进一步降低服务器对更新来源与行为真实性的判断能力。当这些因素叠加出现时, 系统常陷入“拦截阈值收紧导致误杀率上升、阈值放宽导致漏检增加”的结构性权衡。

现有研究主要有三条技术路线, 但尚难形成统一闭环。第一类是几何鲁棒聚合 (如 Krum、Trimmed Mean), 这类方法对明显异常的参数更新有抑制效果, 但在强 Non-IID 条件下易误伤合法的长尾客户端 [4, 5]。第二类是时序信誉与相似性方法 (如 FLTrust、FoolsGold), 引入了跨轮信息以缓解单轮判断的不稳定, 但对“前期伪装、后期小剂量持续投毒”的潜伏攻击仍存在识别滞后的问题 [7, 8]。第三类是可信执行或可验证训练方法 (如 TMT-FL) [14], 重点在训练完整性证明。与此同时, RaSA[12] 等工作强化了异构场景下的聚合鲁棒性, 但在“强异构统计偏移 + 跨轮潜伏攻击 + 开放执行环境”三个不利条件同时出现时, 仍缺少统一状态建模与联动决策机制。基于此, 本文聚焦如下问题: 如何在开放异构边缘联邦中, 同时实现客户端准入可信、聚合过程中对客户端实现低误杀率且高召回率, 并维持模型收敛与泛化性能?

尽管上述思路具有可行性, 但要在同一框架下同时满足这些目标仍面临以下三项关键挑战:

挑战一: 强 Non-IID 条件下的鲁棒性与泛化性冲突。现有方法主要通过距离排斥或统计截断抑制异常更新 [4, 5], 并有工作尝试利用自适应权重缓解异构影响 [12]。但在强长尾分布下, 这类机制仍容易将合法偏斜的参数更新误判为异常参数, 导致关键异构信息被过度剔除, 模型泛化能力下降。

挑战二: 潜伏型复合攻击下的跨轮识别困难。时序信誉与相似性约束可一定程度提升稳健性 [7, 8, 13], 但当攻击者采用“前期积累信誉、后期持续小幅度投毒”的策略时, 单一信誉分与固定阈值机制对深层异常触发特征的识别能力不足, 难以及时识别后门潜伏行为。

挑战三: 开放环境下的训练执行完整性证明缺失。纯软件聚合下的防御通常默认客户端执行过程可信。尽管已有研究通过 TEE 或可验证训练增强执行完整性 (如 TMT-FL、RPPFL) [14, 20, 21],

其重点仍在训练真实性证明，尚未与“强异构下的低误杀聚合”和“潜伏攻击的跨轮识别”形成统一防御闭环。

为应对上述挑战，本文提出软硬件协同的“信任流 (Trust Flow)”可信联邦框架。针对挑战一，我们采用历史效用与瞬时风险解耦聚合过程，并在聚合阶段引入按层门控与动态裁剪，以抑制恶意更新的同时保留合法异构贡献；针对挑战二，我们构建双流正交状态演化 (HistPerf 与 RiskEMA)，以“长期积累 + 瞬时熔断”联合机制增强潜伏攻击识别能力；针对挑战三，我们引入基于 TEE 的远程证明与运行监测，建立客户端侧的强制准入与执行时的可信能力，并将硬件证明与软件风险评估进行时序联动。

本文的主要贡献总结如下：

1. 提出软硬件协同的信任流防御框架。通过“TEE 准入验证 + 内容审查 + 状态演化 + 分层聚合”构建全流程闭环防线，覆盖从客户端接入到模型更新的完整路径。
2. 提出双流正交信誉演化机制。将客户端状态拆分为历史效用流 (HistPerf) 与瞬时风险流 (RiskEMA)，分别处理长期贡献与短时异常，在设定条件下兼顾高恶意召回与低永久误杀。
3. 设计基于纯净参考的分层差异化聚合策略。利用服务器侧参考方向与按层风险门控，实现逐层准入、幸存者重归一化与动态 L2 裁剪，降低深层后门透传风险。
4. 完成端到端实现与实证验证。在 Flower 平台完成 20 客户端、6 类混合攻击实验 ($n = 5$)；结果显示框架在高对抗设置下仍保持 92.31%(±0.09%) 精度、10.21%(±0.05%) ASR，以及接近 0 的永久误杀率。

2 背景与相关工作

2.1 联邦学习与边缘计算协同架构

联邦学习 (Federated Learning, FL) 在“数据不出本地”的约束下，通过参数协同完成全局模型训练。在边缘计算场景中，端-边-云 (Client-Edge-Cloud) 的架构模式已被广泛采用：边缘侧负责本地训练并上传更新，中心服务器负责聚合与模型下发。但是该架构天然存在通信延迟、设备异构和数据 Non-IID 等问题。为缓解这些挑战，已有研究提出簇式联邦 (Clustered FL) [9]、自适应剪枝扩展 (FedPE) [10] 和拆分式联邦 (ParallelSFL) [11] 等方法。但随着系统复杂度提升，攻击面也随之扩大，恶意节点也更易潜伏并影响训练过程。

2.2 边缘伪装、模型投毒与隐蔽后门攻击

在开放且缺少强制准入的联邦网络中，服务器难以准确判断客户端身份与更新质量，攻击手段主要分为两类：其一是无目标投毒 (Untargeted Poisoning)，如 Sign-flipping 与 Gradient Scaling，目标是破坏全局收敛并造成拒绝服务；其二是目标后门攻击 (Targeted Backdoor)，如标签翻转、干净标签污染和语义后门，通过隐蔽触发器在推理阶段诱导定向误分类。

2.3 现有主动防御防线的机制与不可调和的局限性

为应对上述威胁，早期防御多依赖几何统计过滤，例如 Krum[4] 与 Trimmed Mean[5]。近期的研究进一步引入了时序信任评估，如 FLTrust[7]、FoolsGold[8] 与 RaSA[12]，并在恶意检测 [13]、可信训练框架 [14]、分级保护 [15] 等方向持续扩展。针对后门与合谋攻击，也已有 FLPurifier[16]、RoseAgg[17] 和 ShieldFL[18] 等方案。但纯软件防御在强 Non-IID 与高权限攻击下仍有明显短板：阈值收紧会抬高误杀率（FPR），阈值放宽又可能放过潜伏攻击；同时，当攻击者控制底层环境时，缺少硬件信任根的软件探针难以形成完整闭环。

2.4 联邦环境下的可信硬件信任根 (TEE)

为补齐物理可信的缺口，研究开始引入 Intel SGX、ARM TrustZone 等可信执行环境 (TEE)。TEE 通过隔离执行与受保护内存保证关键代码和密钥材料的完整性，即便宿主操作系统被攻陷，攻击者也难以直接篡改证明流程 [19, 20]。现有的工作表明，TEE 在训练完整性 [21]、威胁缓解 [22] 和工业 IoT 信任共享 [23] 中具备现实价值，其在 SGX 环境下的联邦扩展与效率优化也得到验证 [24, 25]。本文在此基础上构建软硬件协同防御体系。与仅做静态加密或单维异常评测的方法不同，本文将硬件远程证明 (Remote Attestation) 与双流信誉演化进行时序耦合：云端负责参数审查，边缘侧 TMAA 提供可信证据与运行时监测，实现“强制准入 + 动态熔断”的联动防护。

3 系统模型与问题定义

3.1 端边云协同架构与系统流转建模

本文考虑一个典型的端-边-云 (Client-Edge-Cloud) 异构通信环境 (见图 1)。系统由中心聚合服务器 (Server, $\mathcal{S}$) 与 K 个边缘客户端组成，记为 $\mathcal{C} = \{c_1, c_2, \dots, c_K\}$ 。客户端可能动态上下线，且部分节点可能被攻击者控制。

训练开始前，系统先通过硬件凭证建立 TEE 可信通道，再执行联邦优化目标，即最小化所有客户端数据分布上的经验风险：

$$\min_W \mathcal{L}(W) = \sum_{k=1}^K p_k \mathcal{L}_k(W) \quad (1)$$

其中 $p_k = |\mathcal{D}_k| / \sum |\mathcal{D}_j|$ 。在第 t 轮，服务器下发全局模型 $W_{global}^{(t-1)}$ ，客户端以其为初值在本地 Non-IID 数据上执行 E 轮学习率为 η_l 的 SGD，得到本地更新：

$$\Delta W_k^{(t)} = W_{k,E}^{(t)} - W_{global}^{(t-1)}, \quad \text{其中 } W_{k,e}^{(t)} = W_{k,e-1}^{(t)} - \eta_l \nabla \mathbb{E}[\ell(W_{k,e-1}^{(t)}; x, y)] \quad (2)$$

其中，期望 $\mathbb{E}[\cdot]$ 表示对本地数据集 $\mathcal{D}_k$ 的 mini-batch 采样期望 (本文设置 batch size=64)。随后，客户端上传更新量及 TEE 签名的远程证明 (Attestation Quote)，服务器基于信任流评分执行鲁棒聚合：

$$W_{global}^{(t)} = W_{global}^{(t-1)} + \text{Agg}(\{\Delta W_k^{(t)}\}_{k \in \Phi}) \quad (3)$$

其中， $\Phi \subseteq \mathcal{C}$ 表示本轮通过审查的有效客户端集合； $\text{Agg}(\cdot)$ 为本文提出的安全聚合算子，具体机制见第 4 节。




图 1: 联邦计算网络交互: 基于 TEE 锚点加密的端边云协同物理架构图

3.2 复合型威胁假设与强信任底座边界 (Threat Model)

为清晰界定攻防能力边界，本文采用如下威胁模型（见图 2）：

- 硬件隔离边界（信任根）：在标准安全假设下（不考虑微架构侧信道与物理探针等高级攻击 [20]），即使宿主操作系统被攻陷，TEE（如 TrustZone/SGX）仍可保证关键执行与证明流程的完整性。
- 诚实但好奇（Honest-but-curious）：服务器按协议执行双流评分和分层聚合流程，但可能尝试额外推断客户端隐私信息。
- 内部恶意客户端（Internal Attackers/Poisoners）：攻击者可持有合法接入身份，并在本地执行标签篡改、样本污染、符号翻转、梯度缩放等操作。本文假设恶意占比上限为 $< 50\%$ ；主实验采用 30% 作为典型高风险设置，并额外给出 50% 边界压力测试。




图 2: 边缘广域网络下的安全渗透与多维复合型投毒威胁模型示意图

3.3 安全架构核心防护优化导向 (Design Goals)

针对高异构数据与高比例恶意参与者，本文框架的设计目标如下：

1. 高防御效能与鲁棒收敛保障：在面对多类投毒与后门攻击时，系统需具备精准的恶意节点识别能力（即高 TPR 与低 ASR），同时确保全局主任务模型的高可用性与稳定收敛。

2. 异构长尾节点的高包容度：有效克服 Non-IID 数据分布带来的特征偏离干扰，避免将携带长尾数据的诚实节点错误剔除，保障系统的假阳性率（FPR）趋近于零。
3. 轻量级开销与边缘适配性：在不引入全量密码学（如全同态加密）计算负担的前提下，构建高效的可信防护机制，确保系统算力与通信开销严格可适应边缘异构设备的资源瓶颈。

4 本文方法：信任流驱动的可信联邦框架

针对上述威胁模型，本文提出“信任流驱动的可信联邦学习”框架（见图 3）。每轮次被划分为五个阶段：训练前准入、内容审查、状态演化、分层聚合和全局下发。不同于单点防御，每阶段产生的数据在该框架内的阶段间持续传递并更新信任流（Trust Flow），形成闭环控制。

Feed Global Knowledge and Reputation back to Edge Terminals (Closed-loop Starts)




图 3: 信任流驱动的可信联邦学习五阶段防御闭环架构总览

为便于后续推导，表 1 给出核心符号定义。

表 1: 核心系统参数与信任流符号定义

符号	定义描述	符号	定义描述
$W_{global}^{(t)}$	第 t 轮的全局模型权重	$\mathcal{A}$	本轮具备有效聚资格格的活跃节点集
ΔW_k	客户端 k 提交的模型梯度/参数更新	$\Phi^{(l)}$	第 l 层的有效安全幸存者子集
$TrustScore_k$	TEE 硬件锚定的准入基础信任分	$HistPerf_k$	历史效用流累积状态 ($HistPerf$)
$ContentScore_k$	双参比下的当轮内容质量得分	$RiskEMA_k$	瞬时风险流衰减状态 ($RiskEMA$)
$RawScore_k$	融合三维得分并施加风险折扣的最终权限分	$M_{attest,k}$	硬件远程证明 (Attestation) 验证结果
g_{root}	服务器提取的纯净指导锚点方向	A_k	客户端 k 的物理资源运行时异常

4.1 阶段一：硬件锚定的客户端准入与信任起步评分

为阻断身份伪造与恶意设备接入，系统引入基于 TEE 的可信管理代理（TMAA）。每轮训练前，客户端需使用不可导出的硬件密钥提交包含 PCR 链值的远程证明（Attestation Quote）。证明通过时记 $M_{attest,k} = 1$ ，否则为 0 且直接拒绝接入。

基于 TMAA 监控日志（如 CPU 行为模式、进程完整性），系统为通过门禁的客户端 k 计算异常分数 $A_k \in [0, \infty)$ ，并据此得到初始信任分 $TrustScore_k \in [0, 1]$ ：

$$TrustScore_k = M_{attest,k} \cdot \exp(-\lambda \cdot \max(0, A_k - \tau)^\rho), \quad (4)$$

其中， λ 控制降分斜率， τ 为正常波动容忍阈值， ρ 为衰减指数（默认 $\lambda = 5.0, \tau = 0.1, \rho = 2.0$ ）。

4.2 阶段二：服务器优先的参考方向构建与同构协调审查

仅依赖客户端之间的余弦相似度容易被合谋攻击误导，为此，本文引入优先纯净参考（Vanilla Reference Prioritization）。当服务器持有少量隔离验证集（Pure Clean Set）时，先计算 g_{root_clean} 作为参考方向；若该方向不可用，则由高信任、低风险客户端更新构造退化参考 g_{ref} 。其权重定义为：

$$\omega_k^{ref} = TrustScore_k \cdot (1 - RiskEMA_k^{prev})^2. \quad (5)$$

最终参考方向 g_{root} 为：

$$g_{root} = \begin{cases} g_{root_clean}, & \text{若服务器验证集方向可用,} \\ \sum_k \frac{\omega_k^{ref}}{\sum_j \omega_j^{ref}} \Delta W_k, & \text{否则.} \end{cases} \quad (6)$$

在得到 g_{root} 后，服务器对每个客户端更新 ΔW_k 计算内容质量分。该分数同时考虑全局贡献（与参考方向一致性）和群体一致性（与其他高信誉客户端一致程度）：

$$S_{contrib,k} = \max(0, \alpha_1 + \alpha_2 \cdot \cos(\Delta W_k, g_{root})), \quad (7)$$

$$S_{consist,k} = \frac{\sum_{j \neq k} TrustScore_j \cdot \max(0, \alpha_1 + \alpha_2 \cdot \cos(\Delta W_k, \Delta W_j))}{\sum_{j \neq k} TrustScore_j + \varepsilon}, \quad (8)$$

$$ContentScore_k = \frac{(1 + \beta_{fusion}^2) \cdot S_{consist,k} \cdot S_{contrib,k}}{\beta_{fusion}^2 \cdot S_{consist,k} + S_{contrib,k} + \varepsilon}. \quad (9)$$

其中， $\alpha_1 + \alpha_2 = 1.0$ 用于调节余弦映射区间； $\beta_{fusion} > 1.0$ （默认 $\beta_{fusion} = 2.0$ ）表示适当提高“与纯净方向一致”的权重，以增强对合谋偏移的抑制能力。

4.3 阶段三：历史绩效流与瞬时风险流的正交状态演化

传统“低分即淘汰”的策略容易误伤长尾合法节点。为此，本文将状态更新拆分为两个正交时序流：用于长期贡献评估的历史效用流（ $HistPerf$ ），以及用于快速处置异常行为的风险流（ $RiskEMA$ ）。

(1) 历史效用流（ $HistPerf$ ）用于长期能力评估，不直接触发封禁。每轮基于 $ContentScore$ 的相对位置（ z_k ）与绝对阈值共同得到更新信号 $Signal_k^{upd}$ ：

$$z_k = \frac{ContentScore_k - \mu_{content}}{\sigma_{content} + \varepsilon}, \quad Signal_k^{rel} = \sigma(z_k), \quad (10)$$

$$Signal_k^{abs} = \text{clip}\left(\frac{ContentScore_k - b}{s}, 0, 1\right), \quad (11)$$

$$Signal_k^{upd} = \gamma_{rel} \cdot Signal_k^{rel} + \gamma_{abs} \cdot Signal_k^{abs}, \quad (12)$$

$$HistPerf_k^{(t)} = \beta_h \cdot HistPerf_k^{(t-1)} + (1 - \beta_h) \cdot Signal_k^{upd}. \quad (13)$$

Algorithm 1 基于 TEE 硬件锚点与纯净参考的准入与内容审查

 输入: 客户端集合 $\mathcal{C}$, 本轮收到的参数更新 $\{\Delta W_k\}_{k \in \mathcal{C}}$, 上轮状态 $RiskEMA^{(t-1)}$

 输出: $TrustScore_k$, $ContentScore_k$, 有效参考基准 g_{root}

```

1: 第一阶段：硬件锚定准入
2: for 每个客户端  $k \in \mathcal{C}$  do
3:   if  $M_{attest,k} == 1$  (TEE 远程证明通过) then
4:     获取物理异常特征  $A_k$ 
5:     门禁信任分  $TrustScore_k \leftarrow \exp(-\lambda \max(0, A_k - \tau)^\rho)$ 
6:   else
7:     拒绝接入:  $TrustScore_k \leftarrow 0$ 
8:   end if
9: end for
10: 第二阶段：参考方向构建与同构审查
11: if 具备服务器纯净验证集数据 then
12:   提取真实指导梯度  $g_{root} \leftarrow g_{root\_clean}$ 
13: else
14:   计算非线性权重  $\omega_k^{ref} \leftarrow TrustScore_k \cdot (1 - RiskEMA_k^{(t-1)})^2$ 
15:   生成降级纯净锚点  $g_{root} \leftarrow \sum_k (\omega_k^{ref} \Delta W_k) / \sum_j \omega_j^{ref}$ 
16: end if
17: for 通过准入的活跃客户端  $k$  do
18:   全局贡献分  $S_{contrib,k} \leftarrow \max(0, \alpha_1 + \alpha_2 \cos(\Delta W_k, g_{root}))$ 
19:   群体协作分  $S_{consist,k} \leftarrow \frac{\sum_{j \neq k} TrustScore_j \max(0, \alpha_1 + \alpha_2 \cos(\Delta W_k, \Delta W_j))}{\sum_{j \neq k} TrustScore_j + \varepsilon}$ 
20:   调和内容分  $ContentScore_k \leftarrow \frac{(1 + \beta_{fusion}^2) S_{consist,k} S_{contrib,k}}{\beta_{fusion}^2 S_{consist,k} + S_{contrib,k} + \varepsilon}$ 
21: end for
22: return  $\{TrustScore_k, ContentScore_k, g_{root}\}$ 

```

其中, b, s 为绝对得分缩放边界; γ_{rel} 与 γ_{abs} (和为 1.0) 分别控制相对与绝对两类信号占比。当 $HistPerf$ 较低时, 节点进入临时软隔离, 暂停本轮聚合但不被永久移除, 以保留潜在有效的长尾信息。

(2) 瞬时风险流 ($RiskEMA$) 负责快速识别攻击行为。该流融合多维探针 (如 $r_{probe}, r_{grad}, r_{trigger}, r_{pixel}$), 并采用每轮最大风险值:

$$Risk_k^{inst} = \max\{r_{report}, r_{grad}, r_{probe}, r_{pixel}, r_{trigger}, r_{sign}, r_{peer}, \dots\}, \quad (14)$$

而后向后做指数衰减记忆 ($\beta_r = 0.85$ 为平滑系数):

$$RiskEMA_k^{(t)} = \beta_r \cdot RiskEMA_k^{(t-1)} + (1 - \beta_r) \cdot Risk_k^{inst}. \quad (15)$$

在双流联合驱动下, 客户端状态按图 4 在四类监管状态间转移:

- 正常节点 (NORMAL): 正常参与聚合。若风险上升或历史贡献下降, 可转入 SUSPECT/QUARANTINE。
- 嫌疑节点 (SUSPECT): 进入重点监控。风险回落可恢复 NORMAL, 持续异常则升级隔离。
- 隔离节点 (QUARANTINE): 暂时剥夺聚合资格, 观察后可恢复或继续升级处理。
- 黑名单 (BLACKLIST): 触发硬阈值后永久封禁, 并在 TEE 认证层终止后续接入。

该机制在保证快速拦截攻击的同时, 为合法长尾节点保留恢复通道, 有助于降低永久误杀。




图 4: 客户端积弊历史与瞬发风险叠加下的四态监管转移自动机逻辑图

最后, 将 $TrustScore$ (硬件可信)、 $ContentScore$ (当轮质量) 与 $HistPerf$ (历史表现) 融合为基础分, 并叠加风险折扣得到 $RawScore_k$:

$$RawScore_k^{base} = (TrustScore_k)^\alpha \cdot (ContentScore_k)^\beta \cdot (HistPerf_k^{(t-1)})^\gamma, \quad (16)$$

$$RawScore_k = RawScore_k^{base} \cdot (1 - RiskEMA_k^{prev})^p, \quad (17)$$

其中, α, β, γ, p 控制各维度对最终聚合权重的影响强度。

Algorithm 2 双流正交信任状态演化 (HistPerf & RiskEMA)

 输入: $ContentScore_k$, 多维风险探针集合 $\{r_{probe}, r_{grad}, \dots\}$

 输出: $HistPerf_k^{(t)}$, 瞬时风险流 $RiskEMA_k^{(t)}$, 全局权值总分 $RawScore_k$

```

1: 流 A: 历史效用流演化 (竞争软权限)
2: 计算全局内容得分均值  $\mu_{content}$  与标准差  $\sigma_{content}$ 
3: for 通过准入的客户端  $k$  do
4:   相对竞争信号  $Signal_k^{rel} \leftarrow \sigma((ContentScore_k - \mu_{content})/(\sigma_{content} + \varepsilon))$ 
5:   绝对基准信号  $Signal_k^{abs} \leftarrow \text{clip}((ContentScore_k - b)/s, 0, 1)$ 
6:   综合增量  $Signal_k^{upd} \leftarrow \gamma_{rel}Signal_k^{rel} + \gamma_{abs}Signal_k^{abs}$ 
7:   更新  $HistPerf_k^{(t)} \leftarrow \beta_h HistPerf_k^{(t-1)} + (1 - \beta_h)Signal_k^{upd}$ 
8: end for
9: 流 B: 瞬时风险惩戒流演化 (一票否决权)
10: for 每个客户端  $k$  do
11:   捕获瞬时风险极值  $Risk_k^{inst} \leftarrow \max\{r_{report}, r_{grad}, r_{probe}, r_{pixel}, r_{trigger}\}$ 
12:   更新  $RiskEMA_k^{(t)} \leftarrow \beta_r RiskEMA_k^{(t-1)} + (1 - \beta_r)Risk_k^{inst}$ 
13:   if  $RiskEMA_k^{(t)} > \text{隔离门限}$  then
14:     加入长期隔离黑名单  $RiskIsolated \leftarrow RiskIsolated \cup \{k\}$ 
15:   end if
16: end for
17: 最终权限融算
18: for 活跃客户端  $k \notin RiskIsolated$  do
19:   融合分数  $RawScore_k \leftarrow (TrustScore_k)^\alpha (ContentScore_k)^\beta (HistPerf_k^{(t-1)})^\gamma$ 
20:   风险折扣  $RawScore_k \leftarrow RawScore_k \cdot (1 - RiskEMA_k^{(t-1)})^p$ 
21: end for
22: return  $\{HistPerf_k^{(t)}, RiskEMA_k^{(t)}, RawScore_k\}$ 

```

4.4 阶段四：风险门控驱动的分层差异化鲁棒聚合

隐蔽后门通常集中在深层参数中，若对整网统一聚合，潜伏更新仍可能透传。为此，本文采用按层（Layer-wise）门控的差异化聚合策略。

第一步，确定本轮活跃客户端集合 $\mathcal{A}$ ：

$$\mathcal{A} = \{k \mid k \notin RiskIsolated \wedge k \notin HistSoftIsolated\}. \quad (18)$$

第二步，对每一层 l 计算综合敏感度 $S_{total}^{(l)}$ （见图 5），该指标由隐私、效用和安全三部分构成：

$$S_{privacy}^{(l)} = \exp\left(-\tau_p \frac{l}{L}\right), \quad (19)$$

$$S_{utility}^{(l)} = \frac{\|g_{ref}^{(l)}\|_2}{\max_m \|g_{ref}^{(m)}\|_2 + \varepsilon}, \quad (20)$$

$$S_{security}^{(l)} = 1 - \frac{\sum_{k \in \mathcal{A}} TrustScore_k \cdot \cos(\Delta W_k^{(l)}, g_{ref}^{(l)})}{\sum_{k \in \mathcal{A}} TrustScore_k + \varepsilon}, \quad (21)$$

$$S_{total}^{(l)} = w_p S_{privacy}^{(l)} + w_u S_{utility}^{(l)} + w_s S_{security}^{(l)}. \quad (22)$$

其中 w_p, w_u, w_s 为归一化权重。若某层 $S_{total}^{(l)}$ 较高，说明该层风险更高，系统将提高准入门槛 $\theta^{(l)}$ 并收紧该层裁剪半径 $C^{(l)}$ 。

第三步，仅允许满足 $RawScore_k \geq \theta^{(l)}$ 的客户端进入该层幸存集 $\Phi^{(l)}$ 。对幸存者执行权重重归一化，并进行 L2 动态裁剪：

$$\Phi^{(l)} = \{k \in \mathcal{A} \mid RawScore_k \geq \theta^{(l)}\}, \quad \tilde{w}_k^{(l)} = \frac{RawScore_k}{\sum_{j \in \Phi^{(l)}} RawScore_j + \varepsilon}, \quad (23)$$

$$scale_k^{(l)} = \max\left(1, \frac{\|\Delta W_k^{(l)}\|_2}{C^{(l)}}\right), \quad \widehat{\Delta W}_k^{(l)} = \frac{\Delta W_k^{(l)}}{scale_k^{(l)}}. \quad (24)$$

第四步，按层加权聚合得到 $\Delta W_{global}^{(l)}$ ：

$$\Delta W_{global}^{(l)} = \sum_{k \in \Phi^{(l)}} \tilde{w}_k^{(l)} \cdot \widehat{\Delta W}_k^{(l)}, \quad (25)$$

4.5 阶段五：全局更新下发与边缘知识留存

分层聚合完成后，服务器将安全增量应用到全局模型： $W_{global}^{new} = W_{global}^{old} + \Delta W_{global}$ ，并同步下发更新后的模型及客户端状态（含 $HistPerf$ ）。至此形成一轮完整闭环，在保证收敛的同时持续过滤恶意更新。

4.6 双流正交解耦的理论保证 (Theoretical Analysis)

传统单一信誉分数（如简单余弦累加）本质上将高维行为压缩到单轴判断。在强 Non-IID 场景下，这会使得漏检（FNR）与误杀（FPR）的冲突加剧。本节给出双流正交机制的理论分析。

引理 1(长尾节点的方差收敛特性, Lemma 1) 设长尾合法客户端 k 的单轮内容分 $ContentScore_k^{(t)}$ 服从期望 μ_{clean} 、方差 σ_{clean}^2 的扰动分布。在刚性阈值 τ_{hard} 下，若 $\tau_{hard} > \mu_{clean} - \sigma_{clean}$ ，该节




图 5: 风险门控驱动的分层自适应审查与动态裁剪机制示意图

Algorithm 3 基于风险门控的分层差异化聚合与动态裁剪

输入: 活跃节点 $\mathcal{A}$, 分数 $RawScore_k$, 分层更新梯度 $\{\Delta W_k^{(l)}\}$, 网络深度 L

输出: 本轮全局梯度安全总成 ΔW_{global}

- 1: 初始化全局增量 $\Delta W_{global} \leftarrow 0$
- 2: for 网络每一层 $l = 1, 2, \dots, L$ do
- 3: 步骤 1: 层级敏感度三维联合测算
- 4: 隐私敏感度 $S_{privacy}^{(l)} \leftarrow \exp(-\tau_p \cdot l/L)$
- 5: 效用敏感度 $S_{utility}^{(l)} \leftarrow \|g_{ref}^{(l)}\|_2 / \max_m \|g_{ref}^{(m)}\|_2$
- 6: 安全敏感度 $S_{security}^{(l)} \leftarrow 1 - \frac{\sum_{k \in \mathcal{A}} TrustScore_k \cos(\Delta W_k^{(l)}, g_{ref}^{(l)})}{\sum_{k \in \mathcal{A}} TrustScore_k + \varepsilon}$
- 7: 总防御诉求敏感度 $S_{total}^{(l)} \leftarrow w_p S_{privacy}^{(l)} + w_u S_{utility}^{(l)} + w_s S_{security}^{(l)}$
- 8: 步骤 2: 动态风险门控与 L2 自适应裁剪
- 9: 拔高本层安全入场分数门槛 $\theta^{(l)} \leftarrow \mu_{base} + \lambda_s \cdot S_{total}^{(l)}$
- 10: 收紧本层恶意振幅裁剪边界 $C^{(l)} \leftarrow C_{base} / (S_{total}^{(l)} + \varepsilon_c)$
- 11: 步骤 3: 幸存节点挑选与二次重调校
- 12: 筛选本层幸存者名单 $\Phi^{(l)} \leftarrow \{k \in \mathcal{A} \mid RawScore_k \geq \theta^{(l)}\}$
- 13: 对幸存者重新归一化有效权重 $\tilde{w}_k^{(l)} \leftarrow RawScore_k / \sum_{j \in \Phi^{(l)}} RawScore_j$
- 14: 依法则执行 L2 等比缩小 $\widehat{\Delta W}_k^{(l)} \leftarrow \Delta W_k^{(l)} / \max(1, \|\Delta W_k^{(l)}\|_2 / C^{(l)})$
- 15: 步骤 4: 分层合并拼接
- 16: 计算本层安全聚合增量 $\Delta W_{global}^{(l)} \leftarrow \sum_{k \in \Phi^{(l)}} \tilde{w}_k^{(l)} \cdot \widehat{\Delta W}_k^{(l)}$
- 17: 拼接连入全局模型更新量 $\Delta W_{global} \leftarrow \Delta W_{global} \cup \Delta W_{global}^{(l)}$
- 18: end for
- 19: return ΔW_{global}

点将有较高概率被持续淘汰。采用历史效用流平滑后, 其稳态期望满足 $\mathbb{E}[HistPerf_k^{(\infty)}] = \mu_{clean}$, 且方差收敛为:

$$\text{Var}(HistPerf_k^{(\infty)}) = \frac{1 - \beta_h}{1 + \beta_h} \sigma_{clean}^2 \quad (26)$$

由于 $0 < \beta_h < 1$, 当 $\beta_h \rightarrow 1$ 时, 短时扰动被显著平滑。只要 μ_{clean} 高于生存阈值, 历史效用流可作为低通滤波器提高合法节点长期存活概率, 理论上支持 $\lim_{t \rightarrow \infty} FPR = 0$ 。

引理 2(高阶潜伏投毒的瞬时冲激响应, Lemma 2)对“长期伪装、间歇爆发”的后门节点 m , 即使其前期累积了较高 $HistPerf$, 在攻击轮次仍会触发异常探针峰值 ($\exists r \in \{r_{grad}, r_{probe}, r_{trigger}\}, r \gg 1$)。由于 $Risk_k^{inst}$ 取多探针最大值, 且 EMA 对输入单调, RiskEMA 轨迹满足下界:

$$RiskEMA_m^{(t)} \geq \max \left(\beta_r \cdot RiskEMA_m^{(t-1)}, \mathcal{F}_{probe}(r_{grad}, r_{probe}, r_{trigger}) \right) \quad (27)$$

当 $\mathcal{F}_{probe}$ 触发异常突变时, 风险值会在短时间内跃升并逼近或超过门限, 从而触发隔离。

定理 1(双流熔断正交解耦, Theorem 1) 在双流机制下, 诚实长尾节点的高方差更新由 $HistPerf$ 通道平滑吸收; 恶意攻击的突发行为则由 $Risk^{inst}$ 通道快速放大并触发熔断。两类信号在判别空间中被解耦处理, 从而缓解单分数机制难以同时优化 FPR 与 ASR 的矛盾。

5 实验与分析

5.1 实验设置与可复现参数

5.1.1 基准环境与系统软硬件栈

实验基于 Flower (1.5.0) 与 PyTorch 实现。所有仿真均部署在一台 Inspur 服务器上, 硬件配置为双路 CPU + 5 块 NVIDIA A10 (24GB) GPU, 软件环境为 Ubuntu 20.04.6 LTS 与 CUDA 12.8。

为保证可复现性, 本文保留了完整日志、代码与启动脚本。需要说明的是: 节点状态轨迹图 (如图 7) 来自固定随机种子 (如 `seed=42`) 的一次代表性运行; Acc、ASR 等总体指标则采用 5 次独立随机种子实验的均值统计。

5.1.2 数据集异构划分方式

模型使用轻量级卷积神经网络, 数据集为 CIFAR-10。为构造 Non-IID 环境, 50000 张训练图像按以下方式划分:

- 共享基础池: 抽取 5000 个类别均衡样本供所有合法节点共享, 用于基础对齐。
- 弱异构群 (Group A, 节点 6-11): Dirichlet($\alpha = 1.0$), 模拟中等程度分布偏斜。
- 强长尾异构群 (Group B & C, 节点 12-19): Dirichlet($\alpha = 0.1$), 客户端类别分布高度偏斜, 更易被传统余弦机制误判。

5.1.3 恶意攻击实例与比例

为评估框架在复杂威胁下的识别能力, 实验在 20 个节点中注入 6 个恶意节点 (占比 30%), 覆盖数据投毒与参数操纵两类攻击:

- Client 0 - 标签翻转 (Label Flip, $\gamma = 0.5$): 将部分样本标签映射到错误类别。
- Client 1 - 触发器后门 (Backdoor, $\gamma = 0.2$): 在 20% 样本中加入触发器并定向标记为目标类 0。
- Client 2 - 干净标签后门 (Clean Label, $\gamma = 0.5$): 扰动目标类输入但保持标签不变, 提升隐蔽性。
- Client 3 - 语义后门 (Semantic, $\gamma = 0.5$): 利用自然语义偏置诱导错误关联。
- Client 4 - 符号翻转 (Sign-Flipping): 对回传梯度执行符号反转 ($\Delta \widehat{W}_k = -\gamma \cdot \Delta W_k$)。
- Client 5 - 梯度缩放 (Gradient Scaling): 将恶意增量放大 100 倍 ($\Delta \widehat{W}_k = 100 \times \Delta W_k$)。
- 女巫与搭便车节点 (Sybil & Free-rider): 额外注入 5 个无有效 TEE 证书节点与 3 个伪造低负载节点, 用于验证阶段一硬件门禁。

前置拦截说明: 上述 8 个外部渗透或资源欺诈节点均在协议阶段被拦截, 要么未通过 TMAA 硬件门禁 ($M_{attest,k} = 0$), 要么因异常行为导致 $TrustScore_k \rightarrow 0$ 。因此, 后续统计的 20 个节点均为通过阶段一准入后的正式参与者。

实验使用的全局超参数与防御组件配置见表 2。

表 2: 基于物理平台的联邦仿真全局超参数与防御组件配置

模块架构归属	防御组件超参数含义与控制作用简述	实验组取值
基础环境与演化轮次	强长尾异构通讯拓扑节点总量 (K)	20 节点
	本地训练 SGD 优化起步参数 ($lr, Momentum$)	0.001, 0.9
双流协同: 阶段 1 $\rightarrow$ 3	TMAA 基准罚时陡峭度 λ , 死区 τ , 衰减指数 ρ	5.0, 0.1, 2.0
	二维同构审查常量约束映射 α_1, α_2 及 β_{fusion}	0.6, 0.4, 2.0
	历史留存平滑阈值 β_h 与瞬发风险半衰期 β_r	0.9, 0.85
逐层裁剪: 阶段 4	得分融合非线性指数调和阈 (α, β, γ, p)	3.0, 1.0, 0.5, 1.0
	门槛拦截控制下界 μ_{base} 及惩戒放大基线 λ_s	0.4, 1.2

运行说明: 正式实验执行 30 轮联邦训练, 每轮本地训练 3 个 Epoch。轨迹图和单次耗时 (3878.53 s) 来自真实 `server.log`; 准确率类指标报告 5 次重复实验均值, 未做插值平滑。

5.2 防御效果实证分析

5.2.1 全局收敛性与攻击防范表现

如图 6 所示, 在 30% 恶意占比下, 模型精度稳定收敛至 92.31%, 后门 ASR 降至 10.21%。

统计可靠性说明: 本节及后续全局指标 (Acc、ASR 等) 均来自 5 次重复实验均值; 节点轨迹图来自单次代表性运行。

50% 恶意占比边界测试: 为验证第 3.2 节假设上限 (恶意占比 $< 50\%$) 附近的行为, 本文额外构建 *Flwr-half* 1:1 对抗环境 (10 恶意 + 10 合法, 覆盖全部 6 类攻击)。结果见表 3。




图 6: 全局收敛准确率 (Accuracy) 与后门攻击成功率 (ASR) 演化曲线

表 3: 50% 恶意占比极限压力测试与标准 30% 基线的对比

实验设置	Acc (%)	ASR (%)	TPR (%)	FPR (%)
标准基线 (30% 恶意, 6/20)	92.31 $\pm$ 0.09	10.21 $\pm$ 0.05	100	0.00
极限测试 (50% 恶意, 10/20)	91.81 $\pm$ 0.10	10.46 $\pm$ 0.06	100	0.00

如表所示，在接近理论边界的强对抗环境下，框架仍保持 91.81% 的准确率，ASR 为 10.46% (接近随机猜测基线 10%)。10 个恶意节点全部被识别并剔除 (TPR=100%)，10 个合法节点无永久误封 (FPR=0%)。此外，30 轮日志显示测试集 Loss 从 0.06362 下降至 0.00883，说明模型在防御条件下仍保持稳定收敛。

5.2.2 信任流追溯与恶意节点封禁剖析

信任流机制的关键在于“及时暴露恶意节点”和“分级处置风险”。图 7 为避免曲线混乱，仅展示 4 个代表性节点：Client 4 (早期参数篡改)、Client 0 (高频显性投毒)、Client 2 (隐蔽潜伏后门) 和合法长尾节点 Client 15。其判定过程如下：

- Client 0 (Label Flip) 与 Client 1 (Backdoor)：两者在 r_{grad} 与 r_{probe} 上持续高风险，至第 8 轮触发 `risk_ema_above_0.90_for_4_rounds`，进入黑名单。
- Client 3 (Semantic)：像素扰动不明显，但长期偏离纯净参考 g_{root_clean} 。其先进入软隔离，随后触发 `risk_soft_isolation_for_8_rounds`，第 16 轮被移除。
- Client 2 (Clean Label)：本地 Loss 表面正常，但长期漂移特征被连击规则命中 (`c2_drift_combo_for_5_rounds`)，第 24 轮完成识别与剔除。
- Client 4 (Sign-Flipping) 与 Client 5 (Gradient Scaling)：前者因方向反转导致 $S_{contrib}$ 迅速降为低值并触发硬封禁；后者因超大振幅命中分层 L2 门控后进入异常处置并被剔除。

结果表明，双流解耦机制能够将“数据异构导致的低分”与“真实攻击行为”分开处理。在包含 6 个恶意节点的设置下，系统达到 TPR=100%。




图 7: 扩展混合攻击下核心节点信任与风险状态时序追踪

5.2.3 异构长尾节点的误杀保障 (FPR 指标分析)

传统距离型方法 (如 Krum[4]、FLTrust[7]) 在 Dirichlet $\alpha = 0.1$ 的强异构环境中容易误判合法长尾节点。本文实验显示: 30 轮训练中所有合法节点均未触发永久封禁, FPR=0%。即使早期部分合法节点 (如 Client 15) 因数据偏斜出现较低 *ContentScore* 并进入 SUSPECT/QUARANTINE, 其 *RiskEMA* 未持续升高, 故仅会受到临时准入限制与分层裁剪。随着后续贡献恢复, *HistPerf* 可逐步回升, 最终合法节点留存率为 100%。

为进一步解释“低误杀”现象, 本文提取干预前后的节点特征并用 t-SNE 可视化。图 8 显示, 双流机制可将恶意簇与合法长尾簇有效分离, 同时保留合法异构节点在主聚合区域内。




图 8: 联邦参与节点特征向量在双流防御前后的 t-SNE 降维对比

5.3 防御机制横向基准对比 (Baseline Comparison)

公平性说明: 所有基线均在与本文完全相同的联邦设置下运行, 包括节点划分 (20 个)、数据异构度 (Dirichlet $\alpha = 0.1$)、攻击配置 (30% 混合攻击)、初始化参数、优化器设置 ($lr = 0.001$, $momentum = 0.9$) 和通信轮次。

在统一环境下, 本文将所提方法与四类经典鲁棒聚合方法进行横向比较:

FedAvg[26] 作为无防御基线, 反映模型在受攻击时的退化程度; Krum[4] 通过最小欧氏距离选择单个代表更新; Trimmed Mean[5] 在坐标维度执行截断均值; FLTrust[7] 借助服务器小规模干净集构造参考向量并按余弦相似度加权。

各方法在该高风险场景下的量化结果见表 4。

结果显示: FedAvg 在混合攻击下 ASR 高达 92.34%; Krum 可将 ASR 降至 12.15%, 但 FPR 升至 64.2%, 准确率降至 64.20%。相比之下, 本文方法在保持 FPR=0% 的同时取得最高准确率 92.31%, 并实现最低 ASR (10.21%)。基于多次重复实验的 Student's *t*-test 显示, 相比强基线 (如 FLTrust) 差异具有统计显著性 ($p < 0.05$)。

5.4 多阶段防御架构消融实验 (Ablation Study)

为评估各防御模块的贡献, 本文采用逐级剥离 (Ablation) 方式, 比较不同阶段组合下的 Acc 与 ASR (见图 9)。

表 4: 不同联邦学习防御策略在 30% 高危混合攻击环境下的性能对比

防御策略	核心机制分类	全局准确率 $\mu \pm \sigma$ (Acc. %)	攻击成功率 $\mu \pm \sigma$ (ASR %)	正常节点误杀率 μ (FPR %)
FedAvg [26]	无防御基线	86.15 $\pm$ 1.2	92.34 $\pm$ 5.1	N/A (*)
Krum [4]	基于欧氏距离	64.20 $\pm$ 2.8	12.15 $\pm$ 0.9	64.20 (**)
Trimmed Mean [5]	坐标轴独立裁剪	71.35 $\pm$ 2.4	38.60 $\pm$ 4.2	N/A (*)
FLTrust [7]	单向信任锚点	81.25 $\pm$ 1.5	15.42 $\pm$ 1.1	21.40 (**)
本文框架 (Trust Flow)	双流解耦 + 层级裁剪	92.31 $\pm$ 0.09	10.21 $\pm$ 0.05	0.00

(*) 注: *FedAvg* 与 *Trimmed Mean* 算法由于自身不具备任何客户端“显式信任评估”或“永久拉黑剔除 (*Ban*)”机制, 其对恶意节点的容忍表现为数值融合或截断计算, 因此 *FPR* 指标不适用于此类算法, 标记为 *N/A*。

(**) 注: 正常节点误杀率 (*FPR*) 这一指标受确定性规则与固化数据样本异构度 (*Dirichlet* 分布) 的强约束。在固定的数据集切分下, 由于防御规则是确定性的, 该类误杀裁决在各次重复实验中观测到方差极小, 因此本列表仅呈报该指标稳定收敛的标量期望均值 μ 。同时, 此处的 *0.00* 专指“永久封禁误杀”, 部分处于瞬时可疑池中的轻度隔离由于具有触底恢复反弹特性, 不计入模型不可挽回的实质性永久击溃错误。




图 9: 多阶段防御机制消融剥离分析

结果表明：1) 仅启用阶段一（TEE 门禁）时，系统可拦截外部伪装节点，但对内部投毒抑制有限，ASR 仍达 75.40%，Acc 约 82.5%；2) 加入阶段三双流演化后，ASR 降至 32.18%，Acc 回升至 88.2%；3) 再加入阶段四分层裁剪后，ASR 进一步降至 10.21%，Acc 提升至 92.40%。这说明各模块存在明显互补性，组合后可同时提升安全性与可用性。

5.5 长尾异构数据分布极限抗压试验 (Sensitivity on Data Heterogeneity)

许多鲁棒聚合方法对 IID 条件依赖较强。为评估本文框架在不同异构强度下的稳定性，本文在四组 Dirichlet 分布 ($\alpha = 100, 1.0, \dots, 0.1$) 下测试全局准确率，结果见图 10。




图 10: 环境数据异构度 (Dirichlet α) 衰减下的各类安全聚合算法健壮性压测对比

从曲线可见：在 $\alpha = 100$ 或 $\alpha = 1.0$ 的弱异构场景下，Krum 与 FLTrust 表现接近本文方法 (Acc 均大于 90%)；但在极端长尾场景 ($\alpha \rightarrow 0.1$) 中，传统距离型方法明显退化，准确率最低降至 64.2%。本文方法在同条件下仍稳定在约 92%，说明双流解耦机制对强异构具有更好的鲁棒性。

此外，本文对关键参数 β_{fusion} 做了离散测试 ($[0.5, 1.0, 2.0, 3.0]$)。较小取值有利于保留长尾节点，但 ASR 风险上升；过大取值会过度偏向同质更新。综合 Acc 与 ASR，最终选择 $\beta_{fusion} = 2.0$ 。

5.6 系统计算与通信额外开销分析 (Overhead Analysis)

尽管框架包含多阶段评估流程，其计算与通信开销仍可控。表 5 显示：边缘侧仅新增 TEE Quote 生成与轻量监测，额外延迟约 12 ~ 15 ms；通信侧每次仅附带约 15 KB 的 TrustReport，相对约 10 MB 量级模型传输，带宽增量低于 0.15%。

代价方面，分层余弦评估会增加服务器端计算量。测试中单轮聚合耗时由 2.10 s 增至 4.85 s。考虑到广域网场景单轮通信通常在数十秒量级，该开销在工程上可接受。

表 5: 传统联邦系统与本可信联邦框架系统的端云开销对比 (20 Client)

系统架构	边缘端额外计算延迟	上行单次通信外加包大小	云端中央聚合总耗时
标准基线 FedAvg	0 ms (Baseline)	0 KB (Baseline)	~ 2.10 s
可信联邦 (Ours)	~ 15 ms (仅 TEE 签名)	~ 15 KB (附加报告)	~ 4.85 s (包含审查与双流)

6 结论与未来展望

本文面向边缘联邦学习在强 Non-IID 与混合攻击下的安全问题, 提出了“硬件可信准入 + 双流信誉演化 + 分层鲁棒聚合”的 Trust-Flow TFL 框架。该框架通过 TEE 提供物理信任根, 并在算法层以 HistPerf 和 RiskEMA 的正交建模实现“低误杀与高召回”的协同。

实验结果表明, 框架在 30% 混合攻击下取得 92.31%(±0.09%) 的准确率与 10.21%(±0.05%) 的 ASR; 在 50% 边界压力测试下仍保持稳定性能, 并实现 TPR=100%、FPR=0% (永久封禁口径)。这说明该方法在强对抗和强异构条件下具有较好的实用性。

局限性与后续工作: 由于部分 TEE-FL 新方法尚未公开可复现实现, 本文未将其纳入同构对比基线, 后续计划随论文定稿开放代码与实验脚本, 便于社区复现和扩展。未来还将把风险探针从 CV 场景扩展到 LLM/NLP 联邦微调任务, 以验证跨模态场景下的泛化能力。

A 瞬发风险流 (Risk Flow) 探针计算机制细节

为增强可复现性与透明度, 本附录给出第 4 节瞬时风险流核心探针 ($r_{grad}, r_{probe}, r_{trigger}$) 的计算细节。第 t 轮聚合时各探针定义如下:

A.1 A.1 梯度方向与幅度物理探针 (r_{grad})

r_{grad} 衡量客户端更新 $\Delta W_k^{(t)}$ 与参考方向 $g_{root}^{(t)}$ 的几何偏离, 用于检测符号翻转与幅度异常。该指标同时考虑方向偏离 (余弦项) 与尺度突变 (L2 异常项):

$$r_{grad,k}^{(t)} = \lambda_d \left(1 - \frac{\Delta W_k^{(t)} \cdot g_{root}^{(t)}}{\|\Delta W_k^{(t)}\| \cdot \|g_{root}^{(t)}\|} \right) + \lambda_m \max \left(0, \frac{\|\Delta W_k^{(t)}\|_2 - \mu^{(t)}}{\sigma^{(t)}} \right) \quad (28)$$

其中, λ_d 与 λ_m 控制方向项和幅度项的权重 (默认均为 0.5); $\mu^{(t)}$ 与 $\sigma^{(t)}$ 分别为第 t 轮入围节点梯度 L2 范数的均值与标准差。

A.2 A.2 小样本先验验证交叉熵探针 (r_{probe})

仅靠距离统计难以识别对非主类的定向污染。 r_{probe} 使用服务器侧小规模纯净探针集 $\mathcal{D}_{probe}$, 比较合并前后交叉熵损失增量 (Loss Surge):

$$r_{probe,k}^{(t)} = \text{ReLU} \left(\mathcal{L}_{CE}(W_{global}^{(t-1)} + \Delta W_k^{(t)}; \mathcal{D}_{probe}) - \mathcal{L}_{CE}(W_{global}^{(t-1)}; \mathcal{D}_{probe}) \right) \quad (29)$$

A.3 A.3 深层神经元隐蔽后门激活探针 ($r_{trigger}$)

针对 Clean-Label 等高隐蔽攻击, 常规统计与验证 Loss 可能不足。 $r_{trigger}$ 通过高层特征激活分布差异进行检测。设 A_k 为客户端模型在验证集上的前置激活输出, $\mathcal{H}(\cdot)$ 表示 Softmax 归一化到概率单形, 以满足 KL 散度计算条件:

$$r_{trigger,k}^{(t)} = \text{KL-Divergence}(\mathcal{H}(A_{base}) \parallel \mathcal{H}(A_k)) \quad (30)$$

上述三类异常信号经归一化融合后形成单轮风险值 $Risk_k^{(t)}$, 并进入 EMA 更新, 用于后续快速熔断决策。

参考文献

- [1] Kairouz P, McMahan H B, Avent B, et al. Advances and Open Problems in Federated Learning[J]. Foundations and Trends in Machine Learning, 2021.
- [2] Gu T, Dolan-Gavitt B, Garg S. BadNets: Identifying Vulnerabilities in the Machine Learning Model Supply Chain[J]. arXiv:1708.06733, 2017.
- [3] Wang B, Yao Y, Shan S, et al. Neural Cleanse: Identifying and Mitigating Backdoor Attacks in Neural Networks[C]. IEEE S&P, 2019.
- [4] Blanchard P, El Mhamdi E M, Guerraoui R, et al. Machine Learning with Adversaries: Byzantine Tolerant Gradient Descent[C]. NeurIPS, 2017.
- [5] Yin D, Chen Y, Kannan R, et al. Byzantine-Robust Distributed Learning: Towards Optimal Statistical Rates[C]. ICML, 2018.
- [6] Pillutla K, Kakade S M, Harchaoui Z. Robust Aggregation for Federated Learning[J]. IEEE Transactions on Signal Processing, 2022.
- [7] Cao X, Fang M, Liu J, et al. FLTrust: Byzantine-Robust Federated Learning via Trust Bootstrapping[J]. NDSS, 2021.
- [8] Fung C, Yoon C J M, Beschastnikh I. The Limitations of Federated Learning in Sybil Settings[C]. RAID, 2020.
- [9] Towards Privacy-Enhanced and Robust Clustered Federated Learning[J].
- [10] FedPE: Adaptive Model Pruning-Expanding for Federated Learning on Mobile Devices[J].
- [11] ParallelSFL: A Novel Split Federated Learning Framework Tackling Heterogeneity Issues[J].
- [12] Wang et al. RaSA: Robust and Adaptive Secure Aggregation for Edge-Assisted Hierarchical Federated Learning[J]. 2025.
- [13] Dou et al. Toward Malicious Clients Detection in Federated Learning[J]. 2025.

- [14] Lu et al. TMT-FL: Enabling Trustworthy Model Training of Federated Learning With Malicious Participants[J]. 2025.
- [15] Wang et al. A Federated Learning Scheme with Adaptive Hierarchical Protection and Multiple Aggregation[J]. 2024.
- [16] FLPurifier: Backdoor Defense in Federated Learning via Decoupled Contrastive Training[J].
- [17] RoseAgg: Robust Defense Against Targeted Collusion Attacks in Federated Learning[J].
- [18] ShieldFL: Mitigating Model Poisoning Attacks in Privacy-Preserving Federated Learning[J].
- [19] Liao et al. Verifiable Deep Learning Inference on Heterogeneous Edge Devices With Trusted Execution Environment[J]. 2024.
- [20] Zhang et al. RPPFL: Robust and Privacy-Preserving Federated Learning via Trusted Execution Environments[J]. 2025.
- [21] A training-integrity privacy-preserving federated learning scheme with trusted execution environment[J].
- [22] Queyrut S, Schiavoni V, Felber P. Mitigating Adversarial Attacks in Federated Learning with Trusted Execution Environments[C]. ICDCS, 2023.
- [23] Secure sharing of industrial IoT data based on distributed trust management and trusted execution environment[J].
- [24] Xu et al. Distributed Learning in Trusted Execution Environment A Case Study of Federated Learning in SGX[J]. 2021.
- [25] Yan et al. An Efficient Greedy Hierarchical Federated Learning Training Method Based on Trusted Execution Environment[J]. 2024.
- [26] McMahan B, Moore E, Ramage D, et al. Communication-Efficient Learning of Deep Networks from Decentralized Data[J]. AISTATS, 2017.