

边缘计算中信任流驱动的可信联邦关键技术研究

Trust Flow-Driven Trusted Federated Learning in Edge Computing: A Study on Key Technologies

匿名作者

摘要

联邦学习 (FL) 通过避免原始数据迁移来支持边缘智能协同训练, 但开放式边缘参与也使聚合过程暴露于不可信执行、模型投毒、隐蔽后门以及严重 Non-IID 偏移等风险之下。现有鲁棒聚合方法往往依赖更严格的阈值来拒绝恶意更新, 却容易同时剔除合法的长尾客户端。本文提出一种信任流驱动的可信联邦学习框架, 将硬件锚定准入、运行时信任证据、双流信誉演化和风险门控分层聚合联系起来。该方法通过历史性能流和瞬时风险流分离长期效用与短期攻击风险, 再利用按层门控、裁剪和幸存者权重重归一化, 在抑制投毒更新的同时保留有价值的异构贡献。基于 Flower/PyTorch 的 CIFAR-10 实验包含 20 个准入客户端、6 类混合攻击和 5 次重复运行; 结果表明, 在 30% 恶意设置下, 该方法达到 92.31% 的准确率和 10.21% 的 ASR, 永久封禁误杀率接近零。

关键词: 联邦学习; 边缘计算; 可信执行环境; 风险建模; 分层聚合; 后门防御

1 引言

联邦学习通过参数交换训练全局模型, 并将数据保留在边缘设备本地 [1, 25]。这一范式适合边缘智能场景, 但当客户端身份、执行完整性和更新语义无法完全可信时, 聚合阶段会变得脆弱。实际边缘网络还同时存在设备异构和强偏斜数据分布, 因此鲁棒聚合必须区分恶意偏移和合法长尾更新。在复合攻击下, 这一区分更加困难, 因为攻击者可能提交投毒参数、注入定向后门, 或利用跨轮伪装降低可见异常。

已有工作从不同角度处理这一问题。Krum 和 Trimmed Mean 等几何或统计防御会剔除离群更新 [4, 5]; FLTrust、FoolsGold、RaSA 以及相关检测方案则利用干净参考、相似性历史或自适应信任机制 [6, 7, 11, 12, 14]。面向后门的防御进一步考察触发器行为或合谋模式 [2, 3, 15, 16, 17]。这些机制仍面临两类反复出现的张力: 静态软件检查不能保证本地执行确实真实; 过强过滤又容易将 Non-IID 长尾更新误判为攻击。TEE 辅助的联邦学习和可信推理系统提供了硬件信任根 [18, 19, 20, 21, 22, 23, 24, 13], 但客户端准入之后, TEE 本身并不能判断真实训练产生的模型更新是否在语义上安全。

本文提出 *Trust Flow*, 一个面向边缘联邦学习的全流程可信聚合框架。其核心思想是让信任证据在准入、审查、时序状态演化和聚合之间持续流动, 而不是把每一轮视作孤立的过滤决策。本文贡献如下:

1. 提出一种 TEE 锚定的动态准入机制, 将远程证明式准入证据与运行时行为熵、卡尔曼滤波结合起来。
2. 提出双流信誉模型, 将历史效用与瞬时攻击风险解耦, 以缓解恶意召回与永久误杀之间的冲突。
3. 提出按层风险门控聚合规则, 结合差异化准入阈值、动态 L2 裁剪和幸存者权重重归一化。
4. 在 Non-IID CIFAR-10 与混合攻击设置下完成端到端评估, 并补充压力测试与消融实验。

2 背景与相关工作

边缘计算中的联邦学习。标准 FL 工作流中, 客户端完成本地训练并向服务器提交参数更新, 服务器聚合后再分发全局模型。该流程保留了数据本地性, 却使服务器高度依赖上传更新的真实性和质量。边缘计算进一步增加了复杂度, 因为客户端的算力、通信稳定性和数据分布均存在差异。簇式 FL、自适应剪枝扩展和拆分式联邦学习已被用于处理异构性和资源约束 [8, 9, 10]。然而, 系统越开放、层级越复杂, 客户端准入、本地执行和更新聚合周围的攻击面也越大。

投毒与后门攻击。FL 中的攻击主要包括无目标投毒和目标后门。符号翻转、梯度缩放等无目标投毒旨在破坏收敛; 标签翻转、触发器后门、干净标签投毒和语义后门则试图保持主任务行为, 同时植入定向误分类。后门攻击尤其棘手, 因为恶意更新可在方向上接近正常更新, 却改变隐藏特征 [2, 3]。在多轮训练中, 攻击者还可能先正常行为以积累信任, 再注入低幅度或间歇式恶意更新。




图 1: TEE 锚定的端-边-云协同架构。

主动防御及其局限。鲁棒聚合通常依赖几何距离、坐标级统计、干净锚点或时序相似性。Krum 与 Trimmed Mean 拒绝或抑制离群更新 [4, 5]; FLTrust 使用服务器端干净参考方向 [6]; FoolsGold 利用历史相似性降低 Sybil 影响 [7]; RaSA 和近期检测框架进一步在边缘辅助场景下调整聚合或安全聚合 [11, 12, 14]。FLPurifier、RoseAgg 和 ShieldFL 等后门防御提高了对触发器和合谋模式的保护能力 [15, 16, 17]。但这些防御对强 Non-IID 分布仍较敏感：阈值严格会增加良性误杀，阈值宽松则会放过隐蔽攻击。

TEE 辅助可信训练。Intel SGX 和 ARM TrustZone 等可信执行环境可提供隔离执行与受保护密钥材料。已有研究展示了 TEE 在可验证推理、鲁棒隐私保护 FL、训练完整性、攻击缓解和工业 IoT 信任共享中的价值 [18, 19, 20, 21, 22, 23, 24, 13]。不过，TEE 准入不能单独判断一个真实训练过程生成的模型更新是否语义安全。因此，Trust Flow 将硬件根准入与跨轮风险建模、分层鲁棒聚合结合起来。

3 系统模型与威胁假设

系统包含中心服务器 $\mathcal{S}$ 与 K 个边缘客户端 $\mathcal{C} = \{c_1, \dots, c_K\}$ 。第 t 轮中，通过准入的客户端接收 $W^{(t-1)}$ ，完成本地训练后上传 $\Delta W_k^{(t)}$ ，服务器更新 $W^{(t)} = W^{(t-1)} + \text{Agg}(\{\Delta W_k^{(t)}\})$ 。全局目标为

$$\min_W \mathcal{L}(W) = \sum_{k=1}^K p_k \mathcal{L}_k(W), \quad p_k = |\mathcal{D}_k| / \sum_j |\mathcal{D}_j|. \quad (1)$$

边缘场景遵循端-边-云 workflow：客户端侧负责本地训练和信任证据生成，服务器侧负责更新审查、信任状态演化和安全聚合。

威胁模型。服务器是诚实但好奇的，并按聚合协议执行。攻击者可控制已准入客户端，并实施标签翻转、触发器后门、干净标签投毒、语义后门、符号翻转和梯度缩放。本文假设恶意客户端比例上界为 $< 50\%$ 。主实验采用 30% 作为典型高风险设置，并额外报告 50% 边界压力测试。TEE 被假定能够在宿主操作系统被攻陷时保护证明关键代码和密钥，但不考虑物理探测和高级微架构侧信道攻击。

设计目标。Trust Flow 旨在：(i) 在混合投毒和后门攻击下保持收敛；(ii) 使合法长尾客户端的永久封禁误杀率 (FPR) 保持较低；(iii) 避免重型密码学开销，同时保持边缘可部署性。图 1 和图 2 分别概括物理工作流与威胁面。

这些目标相互耦合。纯过滤策略中，增强拒绝规则可以提高恶意召回，却会同时剔除本地分布偏离多数方向的良性客户端；放宽规则能保护长尾客户端，却会让低幅度投毒持续存在。Trust Flow 将该问题视为状态分离问题，而不是简单阈值调参：准入证据、内容质量、历史贡献和瞬时风险在最终分层聚合决策之前始终保持为不同信号。

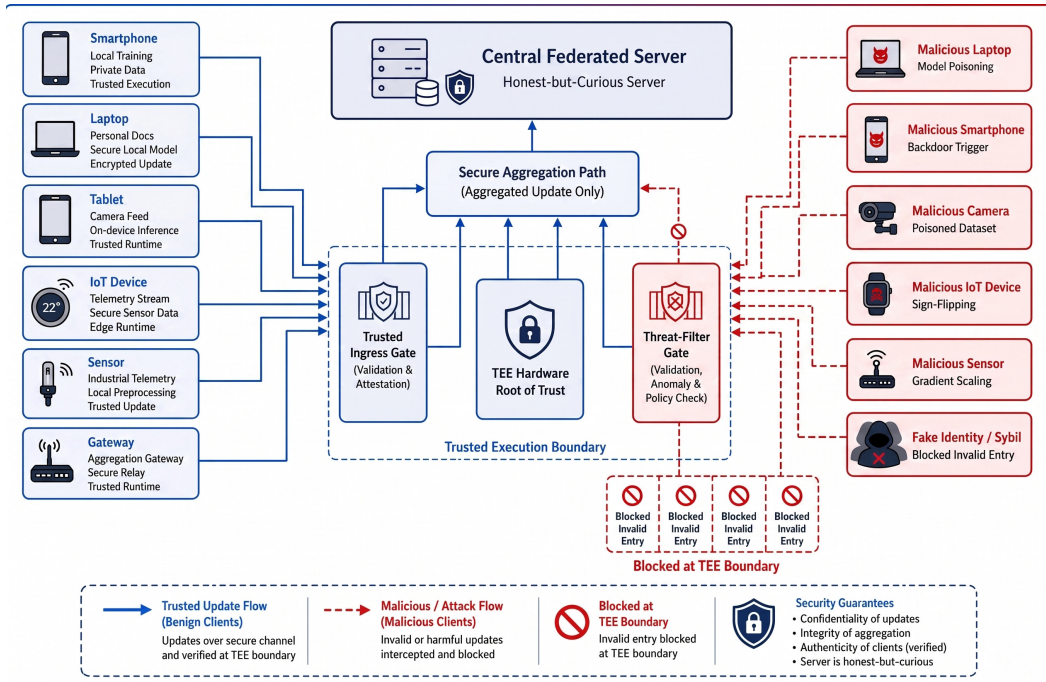


图 2: 复合投毒与渗透威胁模型。

4 Trust-Flow 框架

Trust Flow 将每一轮 FL 划分为四个相互连接的阶段：准入与运行时信任评估、基于参考的内容审查、双流状态演化以及风险门控分层聚合。图 3 展示了完整防御闭环。

从更高层看，该框架是一条信任状态转移管线。第一阶段输出 $TrustScore$ ，刻画客户端是否具有可信参与基础；第二阶段输出 $ContentScore$ ，衡量当前更新是否与干净参考和群体方向一致；第三阶段将这些信号沉淀为 $HistPerf$ 与 $RiskEMA$ ，分离长期贡献和短时异常；第四阶段将状态融合为 $RawScore$ 并执行差异化分层聚合。这一设计避免把某一轮低分直接视为恶意证据，这对强 Non-IID 数据下的长尾客户端尤其重要。

4.1 准入与内容审查

每个准入客户端都必须通过 TEE 式准入检查。令 $M_{attest,k} \in \{0, 1\}$ 表示证明报告是否有效。初始化期间，客户端调用设备唯一密钥并生成远程证明 quote，其中包含 PCR 链、代码段签名和运行配置等完整性测量。只有通过该检查的客户端才获得通信权限。本地训练期间，可信管理代理监测行为序列 $\mathcal{X}_k = \{\Delta grad, \Delta loss, instr_dist\}$ ，并将其熵映射为测量不确定性：

$$H(\mathcal{X}_k) = - \sum_i p(x_i) \log p(x_i), \quad R_k^{(t)} = \exp(\lambda H(\mathcal{X}_k^{(t)})). \quad (2)$$

依据信息论滤波视角 [26] 和多维信任评估方法 [27]，信任估计按下式更新：

$$\hat{T}_k^{(t)} = \hat{T}_k^{(t-1)} + K_k^{(t)}(Z_k^{(t)} - \hat{T}_k^{(t-1)}), \quad TrustScore_k = \hat{T}_k^{(t)}(1 + P_k^{(t)})^{-1}. \quad (3)$$

高熵运行行为会增大 $R_k^{(t)}$ ，降低卡尔曼增益，防止突发异常观测被吸收到长期信任估计中。协方差 $P_k^{(t)}$ 作为置信边界：协方差越小，信任估计越可靠。因此，准入结果不是一次性二元决策，而是可持续更新的权限因子，并可传递到后续审查与聚合阶段。

随后，服务器构造干净指导方向。若存在小型干净验证梯度，则 $g_{root} = g_{root_clean}$ ；否则，使用高信任、低风险客户端：

$$\omega_k^{ref} = TrustScore_k(1 - RiskEMA_k^{prev})^2, \quad g_{root} = \sum_k \frac{\omega_k^{ref}}{\sum_j \omega_j^{ref}} \Delta W_k. \quad (4)$$




图 3: 五阶段信任流防御闭环概览。

对每个客户端更新，内容质量由参考一致性和群体一致性共同构成：

$$S_{contrib,k} = \max(0, \alpha_1 + \alpha_2 \cos(\Delta W_k, g_{root})), \quad (5)$$

$$S_{consist,k} = \frac{\sum_{j \neq k} TrustScore_j \max(0, \alpha_1 + \alpha_2 \cos(\Delta W_k, \Delta W_j))}{\sum_{j \neq k} TrustScore_j + \varepsilon}, \quad (6)$$

$$ContentScore_k = \frac{(1 + \beta_{fusion}^2) S_{consist,k} S_{contrib,k}}{\beta_{fusion}^2 S_{consist,k} + S_{contrib,k} + \varepsilon}. \quad (7)$$

其中 $\beta_{fusion} > 1$ 会提高干净方向的影响，有助于抵抗合谋漂移。

4.2 双流状态演化

单一信誉分会混淆由数据偏斜导致的低效用和由攻击导致的高风险。Trust Flow 因此将客户端状态分为历史效用流和瞬时风险流。历史流使用 Beta 信誉更新：

$$r_k^{good} = \text{clip}((ContentScore_k - \mu_{content}) / (\sigma_{content} + \varepsilon), 0, 1), \quad (8)$$

$$\alpha_k^{(t)} = \lambda_h \alpha_k^{(t-1)} + r_k^{good}, \quad \beta_k^{(t)} = \lambda_h \beta_k^{(t-1)} + (1 - r_k^{good}), \quad (9)$$

$$HistPerf_k^{(t)} = \alpha_k^{(t)} / (\alpha_k^{(t)} + \beta_k^{(t)} + \varepsilon). \quad (10)$$

该通道刻意保持缓慢：合法长尾节点可在暂时低内容分之后恢复。较低 $HistPerf$ 表示该节点近期贡献有限，它会导致软隔离，而不是永久移除。风险流则快速响应，并采用最大探针规则：

$$Risk_k^{inst} = \max\{r_{report}, r_{grad}, r_{probe}, r_{pixel}, r_{trigger}, r_{sign}, r_{peer}\}, \quad (11)$$

$$RiskEMA_k^{(t)} = \beta_r RiskEMA_k^{(t-1)} + (1 - \beta_r) Risk_k^{inst}. \quad (12)$$

探针包括梯度方向与幅度、小型干净集损失上升、触发器激活漂移、报告异常、符号不一致和群体分歧。这两个流只在计算聚合权限时汇合：

$$RawScore_k = (TrustScore_k)^\alpha (ContentScore_k)^\beta (HistPerf_k^{(t-1)})^\gamma \times (1 - RiskEMA_k^{(t-1)})^p. \quad (13)$$

最终状态机区分 NORMAL、SUSPECT、QUARANTINE 与 BLACKLIST，如图 4 所示。潜伏-爆发型攻击者可在早期良性轮次积累较高 $HistPerf$ ，但后续触发注入会激活 $r_{trigger}$ 或 r_{probe} 并提高 $RiskEMA$ ，从而在历史效用较高时仍被阻断。相反，当前相似性较低的长尾良性客户端主要由缓慢效用流处理，并可在后续正向贡献后恢复。

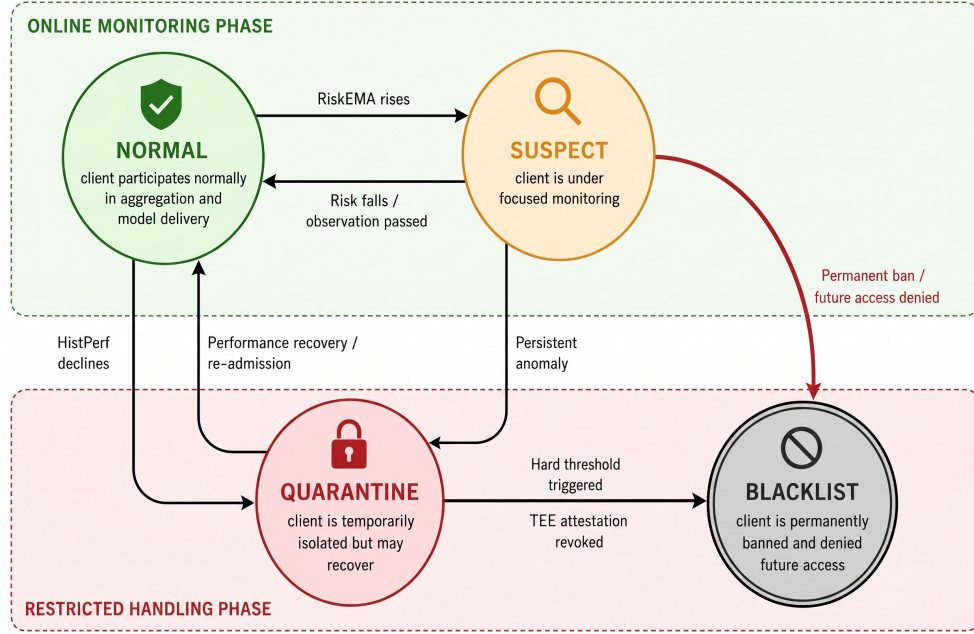


图 4: 由历史效用和瞬时风险驱动的客户状态转移自动机。

4.3 风险门控分层聚合

后门往往集中在深层，而浅层特征层可能携带有价值的异构信息。Trust Flow 因此为每个层 l 分配敏感度分数：

$$S_{privacy}^{(l)} = \exp(-\tau_p l / L), \quad S_{utility}^{(l)} = \|g_{ref}^{(l)}\|_2 / (\max_m \|g_{ref}^{(m)}\|_2 + \varepsilon), \quad (14)$$

$$S_{security}^{(l)} = 1 - \frac{\sum_{k \in \mathcal{A}} TrustScore_k \cos(\Delta W_k^{(l)}, g_{ref}^{(l)})}{\sum_{k \in \mathcal{A}} TrustScore_k + \varepsilon}, \quad (15)$$

$$S_{total}^{(l)} = w_p S_{privacy}^{(l)} + w_u S_{utility}^{(l)} + w_s S_{security}^{(l)}. \quad (16)$$

层阈值和裁剪半径为

$$\theta^{(l)} = \mu_{base} + \lambda_s S_{total}^{(l)}, \quad C^{(l)} = C_{base} / (S_{total}^{(l)} + \varepsilon_c). \quad (17)$$

幸存者集合为 $\Phi^{(l)} = \{k \in \mathcal{A} \mid RawScore_k \geq \theta^{(l)}\}$ ，其权重重新归一化为

$$\tilde{w}_k^{(l)} = \frac{RawScore_k}{\sum_{j \in \Phi^{(l)}} RawScore_j + \varepsilon}, \quad \widehat{\Delta W}_k^{(l)} = \frac{\Delta W_k^{(l)}}{\max(1, \|\Delta W_k^{(l)}\|_2 / C^{(l)})}. \quad (18)$$

最终更新为 $\Delta W_{global}^{(l)} = \sum_{k \in \Phi^{(l)}} \tilde{w}_k^{(l)} \widehat{\Delta W}_k^{(l)}$ 。权重重归一化可以防止剔除风险客户端后有效学习率缩小。

这种按层控制旨在保留有用的浅层表征，同时加固攻击敏感度更高的层。若某个深层的安全项升高，则该层阈值提高、裁剪半径减小，低信任或高幅度更新更难影响该层。若浅层仍接近参考方向，则保持更宽松阈值。这种差异化处理很重要，因为统一裁剪半径会过度压制良性特征提取层，并在恶意客户端已被移出幸存集后拖慢收敛。

4.4 分析视角

双流结构为解释 FPR/ASR 权衡提供了一个简单视角。设合法长尾客户端的单轮内容服从期望为 μ_{clean} 、方差为 σ_{clean}^2 的扰动分布。刚性阈值会在当前分数低于阈值时剔除该客户端，即便偏差来自 Non-IID 数据。经过指数平滑后，历史效用估计的稳态方差遵循标准低通形式：

$$\text{Var}(HistPerf_k^{(\infty)}) = \frac{1 - \beta_h}{1 + \beta_h} \sigma_{clean}^2. \quad (19)$$

当 β_h 接近 1 时，短期良性波动被抑制，客户端更不容易遭到持续移除。相比之下，瞬时风险流会响应攻击冲击。若某个后门轮次产生异常探针值，最大算子会防止该事件在进入 EMA 前被平均掉。因此，将长期贡献和短期风




图 5: 风险门控的按层裁剪与差异化聚合。

险放在不同空间处理，可以减少单分数冲突：长尾更新被平滑而非立即封禁，突发恶意信号则保留足够强度以触发隔离。

4.5 风险探针计算

瞬时风险流使用三个核心探针。梯度探针度量方向和幅度偏离：

$$r_{grad,k}^{(t)} = \lambda_d \left(1 - \frac{\Delta W_k^{(t)} \cdot g_{root}^{(t)}}{\|\Delta W_k^{(t)}\| \|g_{root}^{(t)}\|} \right) + \lambda_m \max \left(0, \frac{\|\Delta W_k^{(t)}\|_2 - \mu^{(t)}}{\sigma^{(t)}} \right). \quad (20)$$

干净探针检查应用某个客户端更新后，小型服务器侧干净集 $\mathcal{D}_{probe}$ 上的交叉熵是否上升：

$$r_{probe,k}^{(t)} = \text{ReLU} \left(\mathcal{L}_{CE}(W^{(t-1)} + \Delta W_k^{(t)}; \mathcal{D}_{probe}) - \mathcal{L}_{CE}(W^{(t-1)}; \mathcal{D}_{probe}) \right). \quad (21)$$

触发器探针通过 KL 散度比较高层特征激活， $r_{trigger,k}^{(t)} = \text{KL}(\mathcal{H}(A_{base}) \parallel \mathcal{H}(A_k))$ ，有助于识别低层梯度方向接近良性更新的干净标签或语义后门。

5 实验

5.1 实验设置

实验使用 Flower 1.5.0 与 PyTorch，在 CIFAR-10 上训练轻量级 CNN。仿真部署在一台 Inspur 服务器上，硬件为双路 CPU 和五块 NVIDIA A10 GPU，软件栈为 Ubuntu 20.04.6 LTS 与 CUDA 12.8。为支持可复现性，完整日志、源代码和启动脚本均予以保留。50000 张训练图像划分给 20 个准入客户端。一个 5000 样本的类别均衡共享池提供共同对齐基础；客户端 6–11 遵循 Dirichlet $\alpha = 1.0$ ，客户端 12–19 使用强长尾划分 $\alpha = 0.1$ 。

正式 30% 攻击设置包含六个恶意客户端：Client 0 执行 $\gamma = 0.5$ 的标签翻转；Client 1 在 20% 样本中注入触发器后门并以类别 0 为目标；Client 2 使用干净标签后门扰动；Client 3 使用语义后门偏置；Client 4 执行符号翻转；Client 5 将更新放大 100 倍。另有五个无有效证书的 Sybil 节点和三个伪造低工作负载的 free-rider 节点用于验证第一阶段门控。这八个节点在统计分析前被拦截，因此后续指标均在 20 个准入客户端上计算。每次运行包含 30 轮和 3 个本地 epoch。Acc/ASR 聚合值取五个随机种子的平均；状态轨迹来自一个代表性种子。

准确率和 ASR 报告为五次独立运行的均值与标准差。永久封禁 FPR 以被不可逆列入黑名单的良性客户端计算，临时 SUSPECT 或 QUARANTINE 状态被视为可恢复控制动作。单次运行轨迹图采用固定种子，以便展

表 1: 紧凑实验配置与主要超参数。

类别	设置	取值
FL 任务	数据集/模型/准入客户端	CIFAR-10/轻量 CNN/ $K = 20$
优化	本地 epoch、学习率、动量、轮次	3, 0.001, 0.9, 30
数据异构	共享池、Group A、Group B/C	5000, $\alpha = 1.0$, $\alpha = 0.1$
信任流	$\alpha_1, \alpha_2, \beta_{fusion}; \beta_h, \beta_r$	0.6, 0.4, 2.0; 0.9, 0.85
分层门控	融合指数; μ_{base}, λ_s	3.0, 1.0, 0.5, 1.0; 0.4, 1.2




图 6: 混合攻击下的主要防御行为。

示节点级转移; 聚合表格使用重复运行结果。所有基线采用相同节点划分、攻击比例、优化器配置、通信轮次和 Non-IID 划分。

5.2 整体防御性能

图 6 总结了收敛、ASR、信任状态轨迹和特征分离结果。在 30% 混合攻击下, Trust Flow 收敛到 92.31% 准确率, 并将 ASR 降至 10.21%, 接近 CIFAR-10 的随机猜测基线。客户端状态追踪显示, 显式投毒与参数攻击会被早期阻断, 而更隐蔽的干净标签漂移则在持续探针证据出现后被捕获。合法长尾节点可能暂时进入 SUSPECT 或 QUARANTINE, 但其风险流不会积累足够证据导致永久封禁。

节点轨迹揭示了不同决策路径。标签翻转和触发器后门客户端表现出持续较高的 r_{grad} 与 r_{probe} , 并在第 8 轮前进入黑名单。语义后门先引发软隔离, 随后在持续风险积累后被移除。干净标签攻击更难检测, 因为其本地损失表现正常; 该攻击在漂移组合规则连续数轮保持激活后被识别。符号翻转显著降低方向贡献分, 梯度缩放则由幅度探针和按层裁剪捕获。相比之下, 长尾良性客户端早期可能内容质量偏低, 但风险流并不持续上升, 因此可通过后续 *HistPerf* 更新恢复。

t-SNE 可视化提供了补充视角。信任流介入前, 恶意客户端和合法长尾客户端可能处在重叠区域, 因为二者都可能偏离多数方向。双流监督后, 恶意客户端形成与高风险探针相关的可分离簇, 而合法长尾客户端仍与主要聚合区域保持连接。这支持了本文的设计主张: 历史效用和瞬时风险不应过早压缩为一个分数。

与 FedAvg 相比, 鲁棒聚合基线能够降低 ASR, 但往往损失大量准确率或移除许多良性长尾客户端。Krum

表 2: 30% 混合攻击与边界压力测试下的性能比较。

方法/设置	核心机制	Acc.	ASR	Perm. FPR
FedAvg [25]	无防御	86.15 ± 1.20	92.34 ± 5.10	N/A
Krum [4]	欧氏选择	64.20 ± 2.80	12.15 ± 0.90	64.20
Trimmed Mean [5]	坐标截断	71.35 ± 2.40	38.60 ± 4.20	N/A
FLTrust [6]	干净锚点加权	81.25 ± 1.50	15.42 ± 1.10	21.40
Trust Flow	双流 + 分层门控	92.31 ± 0.09	10.21 ± 0.05	0.00
边界压力: 50% 恶意	10/20 恶意	91.81 ± 0.10	10.46 ± 0.06	0.00

FPR 表示良性客户端的不可逆误封。临时 SUSPECT/QUARANTINE 状态是可恢复控制动作，并通过轨迹单独呈现。

表 3: 消融与开销概要。

研究项	变体/架构	FPR 或开销	TPR / 时间
信誉	单流 EMA, 激进	18.25% FPR	95.12% TPR
信誉	单流 EMA, 保守	2.10% FPR	48.33% TPR
信誉	HistPerf-only	0.15% FPR	21.05% TPR
信誉	双流 Trust Flow	0.05% FPR	98.50% TPR
开销	标准 FedAvg	额外 0 KB	2.10 s 聚合
开销	Trust Flow	~15 KB TrustReport	4.85 s 含审查

将 ASR 降至 12.15%，但其距离规则排除了大量合法长尾更新，导致准确率仅为 64.20%。Trimmed Mean 在部分轮次比 Krum 更稳定，但坐标截断不足以抑制定向后门。FLTrust 受益于干净锚点，但当合法 Non-IID 更新偏离锚点时仍易受影响。Trust Flow 通过历史平滑保留良性异构贡献，同时用瞬时风险流阻止高信誉攻击者利用历史行为。50% 结果显示，该框架在理论边界附近仍保持稳定，达到 91.81% 准确率和 10.46% ASR。

5.3 消融、敏感性与开销

表 3 表明，单流信誉模型面临 FPR/TPR 权衡：激进阈值增加误封，保守阈值漏检潜伏攻击。仅使用 Hist-Perf 可以保护良性节点，却缺少短期攻击敏感性。双流设计在保持永久误封较低的同时获得较高召回。开销适中：TrustReport 每次上传约增加 15 KB，服务器聚合时间从每轮 2.10 s 增至 4.85 s。

图 7 和图 8 进一步分解了风险探针、权重重归一化和数据异构性的影响。干净参考结合浅层探针能够处理符号翻转和梯度缩放，但在梯度方向与良性更新共线时，干净标签后门仍较难识别。加入交叉熵与高层激活探针后，干净标签 ASR 降至 9.2% 以下。重归一化同样重要：没有幸存者权重修正的分层门控会产生隐式学习率衰减，而完整 Trust Flow 能在 30 轮预算内收敛。在 Dirichlet $\alpha = 0.1$ 下，Krum 与 FLTrust 明显退化，而 Trust Flow 仍保持接近 92% 的准确率。

敏感性曲线显示，当数据接近 IID 时，传统鲁棒聚合表现较好；但随着 α 降低，其性能会下降。在 $\alpha = 100$ 或 $\alpha = 1.0$ 时，Krum 和 FLTrust 与本文方法较接近；在长尾设置 $\alpha = 0.1$ 下，它们的过滤规则越来越容易将合法漂移视为恶意偏移。Trust Flow 对这种变化较不敏感，因为内容证据并不单独使用，而是与历史效用和瞬时风险共同整合。融合参数 β_{fusion} 控制干净参考支配群体一致性的强度。较小取值会保留更多长尾客户端但提高 ASR，较大取值会增强攻击抑制但可能过度惩罚异构更新。默认 $\beta_{fusion} = 2.0$ 在观察结果中取得最好的 Acc/ASR 平衡。

开销分析显示，Trust Flow 主要将成本转移到服务器侧。边缘侧附加约 15 KB 的 TrustReport，并执行轻量运行监测。服务器执行参考构建、成对一致性审查、双流更新和按层裁剪，使聚合时间从测试环境中的 2.10 s 增至 4.85 s。由于广域边缘 FL 轮次通常在通信和同步上的时间远大于聚合计算，该增量对目标场景仍是可接受的。

6 讨论与结论

Trust Flow 将准入证据、内容审查、时序信誉和按层聚合整合为一条统一的信任状态管线。其主要收益不仅是更强的攻击抑制，还在于更清晰地区分两类低更新相似性的来源：良性长尾数据和恶意操纵。这一区分使方法能够在混合攻击下保持较高召回，同时让永久封禁 FPR 接近零。

本文仍存在若干局限。由于多种新兴 TEE-FL 方法尚无公开可复现实现，本研究未能在相同实验设置下将其纳入直接基线。当前探针设计也主要针对视觉分类，尤其是 CIFAR-10 后门行为。后续工作将随最终稿发布源代




图 7: 风险探针与重归一化的组件级消融。




图 8: 不同数据异构度下的鲁棒性压力测试。

码和实验脚本，以支持复现，评估更大规模边缘部署，并将多维风险探针扩展到 NLP 与联邦微调场景。

参考文献

- [1] Kairouz, P., McMahan, H.B., Avent, B., et al.: Advances and open problems in federated learning. Foundations and Trends in Machine Learning 14(1–2), 1–210 (2021). <https://doi.org/10.1561/22000000083>
- [2] Bagdasaryan, E., Veit, A., Hua, Y., Estrin, D., Shmatikov, V.: How To Backdoor Federated Learning. In: Proceedings of the Twenty Third International Conference on Artificial Intelligence and Statistics, PMLR 108, pp. 2938–2948 (2020). <https://proceedings.mlr.press/v108/bagdasaryan20a.html>
- [3] Wang, B., Yao, Y., Shan, S., Li, H., Viswanath, B., Zheng, H., Zhao, B.Y.: Neural Cleanse: Identifying and mitigating backdoor attacks in neural networks. In: 2019 IEEE Symposium on Security and Privacy (SP), pp. 707–723 (2019). <https://doi.org/10.1109/SP.2019.00031>
- [4] Blanchard, P., El Mhamdi, E.M., Guerraoui, R., Stainer, J.: Machine learning with adversaries: Byzantine tolerant gradient descent. In: Advances in Neural Information Processing Systems 30 (2017). [NeurIPS paper page](#)

- [5] Yin, D., Chen, Y., Kannan, R., Bartlett, P.: Byzantine-robust distributed learning: Towards optimal statistical rates. In: Proceedings of the 35th International Conference on Machine Learning, PMLR 80, pp. 5650–5659 (2018). <https://proceedings.mlr.press/v80/yin18a.html>
- [6] Cao, X., Fang, M., Liu, J., Gong, N.Z.: FLTrust: Byzantine-robust federated learning via trust bootstrapping. In: Proceedings 2021 Network and Distributed System Security Symposium (NDSS) (2021). <https://doi.org/10.14722/ndss.2021.24434>
- [7] Fung, C., Yoon, C.J.M., Beschastnikh, I.: The limitations of federated learning in Sybil settings. In: 23rd International Symposium on Research in Attacks, Intrusions and Defenses (RAID 2020), pp. 301–316. USENIX Association (2020). <https://www.usenix.org/conference/raid2020/presentation/fung>
- [8] Xu, Y., Tan, Y., Zhang, C., Sun, P., Zhang, Y., Ren, J., Jiang, H., Zhang, Y.: Towards privacy-enhanced and robust clustered federated learning. IEEE Transactions on Mobile Computing 24(8), 7171–7188 (2025). <https://doi.org/10.1109/TMC.2025.3547149>
- [9] Yi, L., Shi, X., Wang, N., Zhang, J., Wang, G., Liu, X.: FedPE: Adaptive model pruning-expanding for federated learning on mobile devices. IEEE Transactions on Mobile Computing 23(11), 10475–10493 (2024). <https://doi.org/10.1109/TMC.2024.3374706>
- [10] Liao, Y., Xu, Y., Xu, H., Yao, Z., Huang, L., Qiao, C.: ParallelSFL: A novel split federated learning framework tackling heterogeneity issues. In: Proceedings of the 30th Annual International Conference on Mobile Computing and Networking, pp. 845–860 (2024). <https://doi.org/10.1145/3636534.3690665>
- [11] Wang, L., Huang, M., Zhang, Z., Li, M., Wang, J., Gai, K.: RaSA: Robust and adaptive secure aggregation for edge-assisted hierarchical federated learning. IEEE Transactions on Information Forensics and Security 20, 4280–4295 (2025). <https://doi.org/10.1109/TIFS.2025.3559411>
- [12] Dou, Z., Wang, J., Sun, W., Liu, Z., Fang, M.: Toward malicious clients detection in federated learning. In: Proceedings of the 20th ACM Asia Conference on Computer and Communications Security, pp. 456–472 (2025). <https://doi.org/10.1145/3708821.3736194>
- [13] Lu, Z., Wang, L., Zhang, Z., Huang, M., Wang, J., Li, M.: TMT-FL: Enabling trustworthy model training of federated learning with malicious participants. IEEE Transactions on Dependable and Secure Computing 22(3), 2723–2740 (2025). <https://doi.org/10.1109/TDSC.2024.3521377>
- [14] Wang, Z., Yu, X., Tian, Z.: A federated learning scheme with adaptive hierarchical protection and multiple aggregation. In: 2024 IEEE 23rd International Conference on Trust, Security and Privacy in Computing and Communications (TrustCom), pp. 2106–2114 (2024). <https://doi.org/10.1109/TrustCom63139.2024.00292>
- [15] Zhang, J., Zhu, C., Sun, X., Ge, C., Chen, B., Susilo, W., Yu, S.: FLPurifier: Backdoor defense in federated learning via decoupled contrastive training. IEEE Transactions on Information Forensics and Security 19, 4752–4766 (2024). <https://doi.org/10.1109/TIFS.2024.3384846>
- [16] Yang, H., Xi, W., Shen, Y., Wu, C., Zhao, J.: RoseAgg: Robust defense against targeted collusion attacks in federated learning. IEEE Transactions on Information Forensics and Security 19, 2951–2966 (2024). <https://doi.org/10.1109/TIFS.2024.3352415>
- [17] Ma, Z., Ma, J., Miao, Y., Li, Y., Deng, R.H.: ShieldFL: Mitigating model poisoning attacks in privacy-preserving federated learning. IEEE Transactions on Information Forensics and Security 17, 1639–1654 (2022). <https://doi.org/10.1109/TIFS.2022.3169918>
- [18] Liao, L., Zheng, Y., Lu, H., Liu, X., Chen, S., Yu, Y.: Verifiable deep learning inference on heterogeneous edge devices with trusted execution environment. IEEE Sensors Journal 24(17), 28351–28362 (2024). <https://doi.org/10.1109/JSEN.2024.3426533>
- [19] Zhang, X., Chen, Z., Chen, G., Feng, X., Shen, Q., Wu, Z.: RPPFL: Robust and privacy-preserving federated learning via trusted execution environments. In: ICASSP 2025 - 2025 IEEE International Conference on Acoustics, Speech and Signal Processing, pp. 1–5 (2025). <https://doi.org/10.1109/ICASSP49660.2025.10889398>
- [20] Chen, Y., Luo, F., Li, T., Xiang, T., Liu, Z., Li, J.: A training-integrity privacy-preserving federated learning scheme with trusted execution environment. Information Sciences 522, 69–79 (2020). <https://doi.org/10.1016/j.ins.2020.02.037>

- [21] Queyrut, S., Schiavoni, V., Felber, P.: Mitigating adversarial attacks in federated learning with trusted execution environments. In: 2023 IEEE 43rd International Conference on Distributed Computing Systems (ICDCS), pp. 626–637 (2023). <https://doi.org/10.1109/ICDCS57875.2023.00069>
- [22] Zheng, W., Cao, Y., Tan, H.: Secure sharing of industrial IoT data based on distributed trust management and trusted execution environments: A federated learning approach. *Neural Computing and Applications* 35(29), 21499–21509 (2023). <https://doi.org/10.1007/s00521-023-08375-6>
- [23] Xu, T., Zhu, K., Andrzejak, A., Zhang, L.: Distributed learning in trusted execution environment: A case study of federated learning in SGX. In: 2021 7th IEEE International Conference on Network Intelligence and Digital Content (IC-NIDC), pp. 450–454 (2021). <https://doi.org/10.1109/IC-NIDC54101.2021.9660433>
- [24] Yan, J., Li, Y., Yin, S., Kang, X., Wang, J., Zhang, H., Hu, B.: An efficient greedy hierarchical federated learning training method based on trusted execution environments. *Electronics* 13(17), 3548 (2024). <https://doi.org/10.3390/electronics13173548>
- [25] McMahan, B., Moore, E., Ramage, D., Hampson, S., Agueria y Arcas, B.: Communication-efficient learning of deep networks from decentralized data. In: *Proceedings of the 20th International Conference on Artificial Intelligence and Statistics*, PMLR 54, pp. 1273–1282 (2017). <https://proceedings.mlr.press/v54/mcmahan17a.html>
- [26] Chen, B., Liu, X., Zhao, H., Principe, J.C.: Maximum correntropy Kalman filter. *Automatica* 76, 70–77 (2017). <https://doi.org/10.1016/j.automatica.2016.10.004>
- [27] Liu, Y., He, Z., Liang, J., Li, Z., Deng, Q.: Multidimensional trust evaluation and task match based workers recruitment scheme for MCS. *IEEE Transactions on Dependable and Secure Computing*, 1–17 (2026). <https://doi.org/10.1109/TDSC.2026.3652987>