

Trust Flow-Driven Trusted Federated Learning in Edge Computing: A Study on Key Technologies

边缘计算中信任流驱动的可信联邦关键技术研究

周家凯

2026 年 3 月

摘要

面向边缘计算场景，联邦学习在提升数据可用性的同时，也面临 Non-IID 数据、模型投毒与运行环境不确定性叠加带来的鲁棒性挑战。本文提出信任流驱动的可信联邦学习框架，将客户端可信验证、参数审查、历史信誉演化、风险状态更新和分层鲁棒聚合统一为闭环流程。方法上，框架结合硬件门禁与指数衰减信任评分，引入服务器优先的纯净参考方向进行贡献度评估，采用历史流与风险流正交更新，并在聚合阶段执行风险门控下的逐层准入、重归一化与动态裁剪。基于 Flower 在 CIFAR-10 上开展 20 客户端、6 类混合攻击实验。5 轮独立实验 ($n = 5$) 表明：框架可稳定识别恶意客户端，正常节点永久误杀率趋近于 0（瞬时可疑率 $< 0.01\%$ ）；全局准确率达到 $92.31\%(\pm 0.09\%)$ ，后门攻击成功率（ASR）控制在 $10.21\%(\pm 0.05\%)$ ；单次 30 轮仿真耗时 3878.53s。结果表明，该框架在异构边缘环境中具备稳定的恶意节点识别能力与收敛性能。

关键词：联邦学习；边缘计算；可信执行环境；风险状态建模；分层鲁棒聚合；后门防御

Abstract

Federated learning in edge environments faces compound risks from data heterogeneity, model poisoning, and runtime trust uncertainty. This paper presents a trust flow-driven trusted federated learning framework that unifies trusted report verification, content auditing, historical reputation evolution, risk-state updating, and layer-wise robust aggregation into a closed-loop pipeline. The proposed method combines hard attestation gating with exponential trust attenuation, introduces a server-prioritized clean reference for contribution validation, and adopts orthogonal dual-stream updates (history stream and risk stream). During aggregation, risk-gated layer-wise admission, survivor re-normalization, and dynamic clipping are jointly applied. We implement the framework on Flower and evaluate it on CIFAR-10 with 20 clients under six mixed attack types. Statistical results over 5 independent runs ($n = 5$) show that malicious clients are effectively identified with negligible permanent impact on benign nodes. The framework achieves an average accuracy of $92.31\% (\pm 0.09\%)$ and maintains an average ASR of $10.21\% (\pm 0.05\%)$, with a representative benchmark runtime of 3878.53s. The results indicate that trust-flow orthogonal modeling provides robust malicious-client detection while maintaining practical convergence under heterogeneous edge settings.

1 引言

联邦学习（Federated Learning, FL）通过“数据不出本地、仅交换模型参数”的机制，在保护数据隐私的同时实现多方协同建模 [1]。该模式已成为边缘智能的重要基础能力，并在工业物联网、

医疗诊断等场景中得到广泛应用。随着 FL 从实验环境走向开放网络，系统性能不再仅由模型结构与优化器决定，聚合阶段的可信性与稳健性日益成为影响整体可用性的关键因素。究其原因在于：边缘端数据天然分布异构、设备能力具有显著的差异、参与方行为难以完全约束，这些特征在云端聚合时会显著放大统计偏移与安全风险。

在标准 FL 流程中，客户端在本地完成训练并上传更新参数，服务器执行聚合参数后下发新模型，训练通过多轮迭代达到收敛，但是该训练流程在真实边缘计算环境中面临三重安全风险。首先，Non-IID 数据会增加最优更新的方向离散度，使“正常波动”与“异常偏移”的边界变得不清晰。其次，攻击者可实施参数投毒与隐蔽后门等攻击（如干净标签污染、语义后门）[2, 3]，并将恶意触发特征嵌入常规更新分布参数，降低单轮检测成功率。最后，由于开放执行环境缺少强制完整性约束，客户端可能绕过真实训练过程直接构造上报训练参数，进一步降低服务器对更新来源与行为真实性的判断能力。当这些因素叠加出现时，系统常陷入“拦截阈值收紧导致误杀率上升、阈值放宽导致漏检增加”的结构性权衡。

现有研究主要有三条技术路线，但尚难形成统一闭环。第一类是几何鲁棒聚合（如 Krum、Trimmed Mean），这类方法对明显异常的参数更新有抑制效果，但在强 Non-IID 条件下易误伤合法的长尾客户端 [4, 5]。第二类是时序信誉与相似性方法（如 FLTrust、FoolsGold），引入了跨轮信息以缓解单轮判断的不稳定，但对“前期伪装、后期小剂量持续投毒”的潜伏攻击仍存在识别滞后的问题 [7, 8]。第三类是可信执行或可验证训练方法（如 TMT-FL）[14]，重点在训练完整性证明。与此同时，RaSA[12] 等工作强化了异构场景下的聚合鲁棒性，但在“强异构统计偏移 + 跨轮潜伏攻击 + 开放执行环境”三个不利条件同时出现时，仍缺少统一状态建模与联动决策机制。基于此，本文聚焦如下问题：如何在开放异构边缘联邦中，同时实现客户端准入可信、聚合过程中对客户端实现低误杀率且高召回率，并维持模型收敛与泛化性能？

尽管上述思路具有可行性，但要在同一框架下同时满足这些目标仍面临以下三项关键挑战：

挑战一：强 Non-IID 条件下的鲁棒性与泛化性冲突。现有方法主要通过距离排斥或统计截断抑制异常更新 [4, 5]，并有工作尝试利用自适应权重缓解异构影响 [12]。但在强长尾分布下，这类机制仍容易将合法偏斜的参数更新误判为异常参数，导致关键异构信息被过度剔除，模型泛化能力下降。

挑战二：潜伏型复合攻击下的跨轮识别困难。时序信誉与相似性约束可一定程度提升稳健性 [7, 8, 13]，但当攻击者采用“前期积累信誉、后期持续小幅度投毒”的策略时，单一信誉分与固定阈值机制对深层异常触发特征的识别能力不足，难以及时识别后门潜伏行为。

挑战三：开放环境下的训练执行完整性证明缺失。纯软件聚合下的防御通常默认客户端执行过程可信。尽管已有研究通过 TEE 或可验证训练增强执行完整性（如 TMT-FL、RPPFL）[14, 20, 21]，其重点仍在训练真实性证明，尚未与“强异构下的低误杀聚合”和“潜伏攻击的跨轮识别”形成统一防御闭环。

为应对上述挑战，本文提出软硬件协同的“信任流 (Trust Flow)”可信联邦框架。针对挑战一，我们采用历史效用与瞬时风险解耦聚合过程，并在聚合阶段引入按层门控与动态裁剪，以抑制恶意更新的同时保留合法异构贡献；针对挑战二，我们构建双流正交状态演化 (HistPerf 与 RiskEMA)，以“长期积累 + 瞬时熔断”联合机制增强潜伏攻击识别能力；针对挑战三，我们引入基于 TEE 的远程证明与运行监测，建立客户端侧的强制准入与执行时的可信能力，并将硬件证明与软件风险评估进行时序联动。

本文的主要贡献总结如下：

1. 提出软硬件协同的信任流防御框架。通过“TEE 准入验证 + 内容审查 + 状态演化 + 分层聚合”构建全流程闭环防线，覆盖从客户端接入到模型更新的完整路径。
2. 提出双流正交信誉演化机制。将客户端状态拆分为历史效用流（HistPerf）与瞬时风险流（RiskEMA），分别处理长期贡献与短时异常，在设定条件下兼顾高恶意召回与低永久误杀。
3. 设计基于纯净参考的分层差异化聚合策略。利用服务器侧参考方向与按层风险门控，实现逐层准入、幸存者重归一化与动态 L2 裁剪，降低深层后门透传风险。
4. 完成端到端实现与实证验证。在 Flower 平台完成 20 客户端、6 类混合攻击实验 ($n = 5$)；结果显示框架在高对抗设置下仍保持 92.31%(±0.09%) 精度、10.21%(±0.05%) ASR，以及接近 0 的永久误杀率。

2 背景与相关工作

2.1 联邦学习与边缘计算协同架构

联邦学习（Federated Learning, FL）在“数据不出本地”的约束下，通过参数协同完成全局模型训练。在边缘计算场景中，端-边-云（Client-Edge-Cloud）的架构模式已被广泛采用：边缘侧负责本地训练并上传更新，中心服务器负责聚合与模型下发。但是该架构天然存在通信延迟、设备异构和数据 Non-IID 等问题。为缓解这些挑战，已有研究提出簇式联邦（Clustered FL）[9]、自适应剪枝扩展（FedPE）[10] 和拆分式联邦（ParallelSFL）[11] 等方法。但随着系统复杂度提升，攻击面也随之扩大，恶意节点也更易潜伏并影响训练过程。

2.2 边缘伪装、模型投毒与隐蔽后门攻击

在开放且缺少强制准入的联邦网络中，服务器难以准确判断客户端身份与更新质量，攻击手段主要分为两类：其一是无目标投毒（Untargeted Poisoning），如 Sign-flipping 与 Gradient Scaling，目标是破坏全局收敛并造成拒绝服务；其二是目标后门攻击（Targeted Backdoor），如标签翻转、干净标签污染和语义后门，通过隐蔽触发器在推理阶段诱导定向误分类。

2.3 现有主动防御防线的机制与不可调和的局限性

为应对上述威胁，早期防御多依赖几何统计过滤，例如 Krum[4] 与 Trimmed Mean[5]。近期的研究进一步引入了时序信任评估，如 FLTrust[7]、FoolsGold[8] 与 RaSA[12]，并在恶意检测 [13]、可信训练框架 [14]、分级保护 [15] 等方向持续扩展。针对后门与合谋攻击，也已有 FLPurifier[16]、RoseAgg[17] 和 ShieldFL[18] 等方案。但纯软件防御在强 Non-IID 与高权限攻击下仍有明显短板：阈值收紧会抬高误杀率（FPR），阈值放宽又可能放过潜伏攻击；同时，当攻击者控制底层环境时，缺少硬件信任根的软件探针难以形成完整闭环。

2.4 联邦环境下的可信硬件信任根 (TEE)

为补齐物理可信的缺口，研究开始引入 Intel SGX、ARM TrustZone 等可信执行环境（TEE）。TEE 通过隔离执行与受保护内存保证关键代码和密钥材料的完整性，即便宿主操作系统被攻陷，

攻击者也难以直接篡改证明流程 [19, 20]。现有的工作表明, TEE 在训练完整性 [21]、威胁缓解 [22] 和工业 IoT 信任共享 [23] 中具备现实价值, 其在 SGX 环境下的联邦扩展与效率优化也得到验证 [24, 25]。本文在此基础上构建软硬件协同防御体系。与仅做静态加密或单维异常评测的方法不同, 本文将硬件远程证明 (Remote Attestation) 与双流信誉演化进行时序耦合: 云端负责参数审查, 边缘侧 TMAA 提供可信证据与运行时监测, 实现“强制准入 + 动态熔断”的联动防护。

3 系统模型与问题定义

3.1 端边云协同架构与系统流转建模

本文考虑一个典型的端-边-云 (Client-Edge-Cloud) 异构通信环境 (见图 1)。系统由中心聚合服务器 (Server, $\mathcal{S}$) 与 K 个边缘客户端组成, 记为 $\mathcal{C} = \{c_1, c_2, \dots, c_K\}$ 。客户端可能动态上下线, 且部分节点可能被攻击者控制。




图 1: 联邦计算网络交互: 基于 TEE 锚点加密的端边云协同物理架构图

训练开始前, 系统先通过硬件凭证建立 TEE 可信通道, 再执行联邦优化目标, 即最小化所有

客户端数据分布上的经验风险：

$$\min_W \mathcal{L}(W) = \sum_{k=1}^K p_k \mathcal{L}_k(W) \quad (1)$$

其中 $p_k = |\mathcal{D}_k| / \sum |\mathcal{D}_j|$ 。在第 t 轮, 服务器下发全局模型 $W_{global}^{(t-1)}$, 客户端以其为初值在本地 Non-IID 数据上执行 E 轮学习率为 η_l 的 SGD, 得到本地更新：

$$\Delta W_k^{(t)} = W_{k,E}^{(t)} - W_{global}^{(t-1)}, \quad \text{其中 } W_{k,e}^{(t)} = W_{k,e-1}^{(t)} - \eta_l \nabla \mathbb{E}[\ell(W_{k,e-1}^{(t)}; x, y)] \quad (2)$$

其中, 期望 $\mathbb{E}[\cdot]$ 表示对本地数据集 $\mathcal{D}_k$ 的 mini-batch 采样期望 (本文设置 batch size=64)。随后, 客户端上传更新量及 TEE 签名的远程证明 (Attestation Quote), 服务器基于信任流评分执行鲁棒聚合：

$$W_{global}^{(t)} = W_{global}^{(t-1)} + \text{Agg}(\{\Delta W_k^{(t)}\}_{k \in \Phi}) \quad (3)$$

其中, $\Phi \subseteq \mathcal{C}$ 表示本轮通过审查的有效客户端集合; $\text{Agg}(\cdot)$ 为本文提出的安全聚合算子, 具体机制见第 4 节。

3.2 复合型威胁假设与强信任底座边界 (Threat Model)

为清晰界定攻防能力边界, 本文采用如下威胁模型 (见图 2)：

- 硬件隔离边界 (信任根)：在标准安全假设下 (不考虑微架构侧信道与物理探针等高级攻击 [20]), 即使宿主操作系统被攻陷, TEE (如 TrustZone/SGX) 仍可保证关键执行与证明流程的完整性。
- 诚实但好奇 (Honest-but-curious)：服务器按协议执行双流评分和分层聚合流程, 但可能尝试额外推断客户端隐私信息。
- 内部恶意客户端 (Internal Attackers/Poisoners)：攻击者可持有合法接入身份, 并在本地执行标签篡改、样本污染、符号翻转、梯度缩放等操作。本文假设恶意占比上限为 $< 50\%$; 主实验采用 30% 作为典型高风险设置, 并额外给出 50% 边界压力测试。

3.3 安全架构核心防护优化导向 (Design Goals)

针对高异构数据与高比例恶意参与者, 本文框架的设计目标如下：

1. 高防御效能与鲁棒收敛保障：在面对多类投毒与后门攻击时, 系统需具备精准的恶意节点识别能力 (即高 TPR 与低 ASR), 同时确保全局主任务模型的高可用性与稳定收敛。
2. 异构长尾节点的高包容度：有效克服 Non-IID 数据分布带来的特征偏离干扰, 避免将携带长尾数据的诚实节点错误剔除, 保障系统的假阳性率 (FPR) 趋近于零。
3. 轻量级开销与边缘适配性：在不引入全量密码学 (如全同态加密) 计算负担的前提下, 构建高效的可靠防护机制, 确保系统算力与通信开销严格可适应边缘异构设备的资源瓶颈。




图 2: 边缘广域网络下的安全渗透与多维复合型投毒威胁模型示意图

4 本文方法：信任流驱动的可信联邦框架

针对上述威胁模型，本文提出“信任流驱动的可信联邦学习”框架（见图 3）。每轮次被划分为五个阶段：训练前准入、内容审查、状态演化、分层聚合和全局下发。不同于单点防御，每阶段产生的数据在该框架内的阶段间持续传递并更新信任流（Trust Flow），形成闭环控制。

为便于后续推导，表 1 给出核心符号定义。

表 1: 核心系统参数与信任流符号定义

符号	定义描述	符号	定义描述
$W_{global}^{(t)}$	第 t 轮的全局模型权重	$\mathcal{A}$	本轮具备有效聚合格格的活跃节点
ΔW_k	客户端 k 提交的模型梯度/参数更新	$\Phi^{(l)}$	第 l 层的有效安全幸存者子集
$TrustScore_k$	TEE 硬件锚定的准入基础信任分	$HistPerf_k$	历史效用流累积状态 ($HistPerf_k$)
$ContentScore_k$	双参比下的当轮内容质量得分	$RiskEM A_k$	瞬时风险流衰减状态 ($RiskEM A_k$)
$RawScore_k$	融合三维得分并施加风险折扣的最终权限分	$M_{attest,k}$	硬件远程证明 (Attestation) 验证
g_{root}	服务器提取的纯净指导锚点方向	A_k	客户端 k 的物理资源运行时异常




图 3: 信任流驱动的可信联邦学习五阶段防御闭环架构总览

4.1 阶段一：硬件锚定的客户端准入与信任起步评分

为阻断身份伪造与恶意设备接入，系统引入基于 TEE 的可信管理代理（TMAA）。每轮训练前，客户端需使用不可导出的硬件密钥提交包含 PCR 链值的远程证明（Attestation Quote）。证明通过时记 $M_{attest,k} = 1$ ，否则为 0 且直接拒绝接入。

基于 TMAA 监控日志（如 CPU 行为模式、进程完整性），系统为通过门禁的客户端 k 计算异常分数 $A_k \in [0, \infty)$ ，并据此得到初始信任分 $TrustScore_k \in [0, 1]$ ：

$$TrustScore_k = M_{attest,k} \cdot \exp(-\lambda \cdot \max(0, A_k - \tau)^\rho), \quad (4)$$

其中， λ 控制降分斜率， τ 为正常波动容忍阈值， ρ 为衰减指数（默认 $\lambda = 5.0, \tau = 0.1, \rho = 2.0$ ）。

4.2 阶段二：服务器优先的参考方向构建与同构协调审查

仅依赖客户端之间的余弦相似度容易被合谋攻击误导，为此，本文引入优先纯净参考（Vanilla Reference Prioritization）。当服务器持有少量隔离验证集（Pure Clean Set）时，先计算 g_{root_clean} 作为参考方向；若该方向不可用，则由高信任、低风险客户端更新构造退化参考 g_{ref} 。其权重定义为：

$$\omega_k^{ref} = TrustScore_k \cdot (1 - RiskEMA_k^{prev})^2. \quad (5)$$

最终参考方向 g_{root} 为：

$$g_{root} = \begin{cases} g_{root_clean}, & \text{若服务器验证集方向可用,} \\ \sum_k \frac{\omega_k^{ref}}{\sum_j \omega_j^{ref}} \Delta W_k, & \text{否则.} \end{cases} \quad (6)$$

在得到 g_{root} 后，服务器对每个客户端更新 ΔW_k 计算内容质量分。该分数同时考虑全局贡献（与参考方向一致性）和群体一致性（与其他高信誉客户端一致程度）：

$$S_{contrib,k} = \max(0, \alpha_1 + \alpha_2 \cdot \cos(\Delta W_k, g_{root})), \quad (7)$$

$$S_{consist,k} = \frac{\sum_{j \neq k} TrustScore_j \cdot \max(0, \alpha_1 + \alpha_2 \cdot \cos(\Delta W_k, \Delta W_j))}{\sum_{j \neq k} TrustScore_j + \varepsilon}, \quad (8)$$

$$ContentScore_k = \frac{(1 + \beta_{fusion}^2) \cdot S_{consist,k} \cdot S_{contrib,k}}{\beta_{fusion}^2 \cdot S_{consist,k} + S_{contrib,k} + \varepsilon}. \quad (9)$$

其中, $\alpha_1 + \alpha_2 = 1.0$ 用于调节余弦映射区间; $\beta_{fusion} > 1.0$ (默认 $\beta_{fusion} = 2.0$) 表示适当提高“与纯净方向一致”的权重, 以增强对合谋偏移的抑制能力。

Algorithm 1 基于 TEE 硬件锚点与纯净参考的准入与内容审查

输入: 客户端集合 $\mathcal{C}$, 本轮收到的参数更新 $\{\Delta W_k\}_{k \in \mathcal{C}}$, 上轮状态 $RiskEMA^{(t-1)}$

输出: $TrustScore_k$, $ContentScore_k$, 有效参考基准 g_{root}

```

1: 第一阶段: 硬件锚定准入
2: for 每个客户端  $k \in \mathcal{C}$  do
3:   if  $M_{attest,k} == 1$  (TEE 远程证明通过) then
4:     获取物理异常特征  $A_k$ 
5:     门禁信任分  $TrustScore_k \leftarrow \exp(-\lambda \max(0, A_k - \tau)^\rho)$ 
6:   else
7:     拒绝接入:  $TrustScore_k \leftarrow 0$ 
8:   end if
9: end for
10: 第二阶段: 参考方向构建与同构审查
11: if 具备服务器纯净验证集数据 then
12:   提取真实指导梯度  $g_{root} \leftarrow g_{root\_clean}$ 
13: else
14:   计算非线性权重  $\omega_k^{ref} \leftarrow TrustScore_k \cdot (1 - RiskEMA_k^{(t-1)})^2$ 
15:   生成降级纯净锚点  $g_{root} \leftarrow \sum_k (\omega_k^{ref} \Delta W_k) / \sum_j \omega_j^{ref}$ 
16: end if
17: for 通过准入的活跃客户端  $k$  do
18:   全局贡献分  $S_{contrib,k} \leftarrow \max(0, \alpha_1 + \alpha_2 \cos(\Delta W_k, g_{root}))$ 
19:   群体协作分  $S_{consist,k} \leftarrow \frac{\sum_{j \neq k} TrustScore_j \max(0, \alpha_1 + \alpha_2 \cos(\Delta W_k, \Delta W_j))}{\sum_{j \neq k} TrustScore_j + \varepsilon}$ 
20:   调和内容分  $ContentScore_k \leftarrow \frac{(1 + \beta_{fusion}^2) S_{consist,k} S_{contrib,k}}{\beta_{fusion}^2 S_{consist,k} + S_{contrib,k} + \varepsilon}$ 
21: end for
22: return  $\{TrustScore_k, ContentScore_k, g_{root}\}$ 

```

4.3 阶段三：历史绩效流与瞬时风险流的正交状态演化

传统“低分即淘汰”的策略容易误伤长尾合法节点。为此, 本文将状态更新拆分为两个正交时序流: 用于长期贡献评估的历史效用流 ($HistPerf$), 以及用于快速处置异常行为的风险流 ($RiskEMA$)。

(1) 历史效用流 ($HistPerf$) 用于长期能力评估, 不直接触发封禁。每轮基于 $ContentScore$

的相对位置 (z_k) 与绝对阈值共同得到更新信号 $Signal_k^{upd}$:

$$z_k = \frac{ContentScore_k - \mu_{content}}{\sigma_{content} + \varepsilon}, \quad Signal_k^{rel} = \sigma(z_k), \quad (10)$$

$$Signal_k^{abs} = \text{clip}\left(\frac{ContentScore_k - b}{s}, 0, 1\right), \quad (11)$$

$$Signal_k^{upd} = \gamma_{rel} \cdot Signal_k^{rel} + \gamma_{abs} \cdot Signal_k^{abs}, \quad (12)$$

$$HistPerf_k^{(t)} = \beta_h \cdot HistPerf_k^{(t-1)} + (1 - \beta_h) \cdot Signal_k^{upd}. \quad (13)$$

其中, b, s 为绝对得分缩放边界; γ_{rel} 与 γ_{abs} (和为 1.0) 分别控制相对与绝对两类信号占比。当 $HistPerf$ 较低时, 节点进入临时软隔离, 暂停本轮聚合但不被永久移除, 以保留潜在有效的长尾信息。

(2) 瞬时风险流 ($RiskEMA$) 负责快速识别攻击行为。该流融合多维探针 (如 $r_{probe}, r_{grad}, r_{trigger}, r_{pixel}$), 并采用每轮最大风险值:

$$Risk_k^{inst} = \max\{r_{report}, r_{grad}, r_{probe}, r_{pixel}, r_{trigger}, r_{sign}, r_{peer}, \dots\}, \quad (14)$$

而后向后做指数衰减记忆 ($\beta_r = 0.85$ 为平滑系数):

$$RiskEMA_k^{(t)} = \beta_r \cdot RiskEMA_k^{(t-1)} + (1 - \beta_r) \cdot Risk_k^{inst}. \quad (15)$$

在双流联合驱动下, 客户端状态按图 4 在四类监管状态间转移:

- 正常节点 (NORMAL): 正常参与聚合。若风险上升或历史贡献下降, 可转入 SUSPECT/QUARANTINE。
- 嫌疑节点 (SUSPECT): 进入重点监控。风险回落可恢复 NORMAL, 持续异常则升级隔离。
- 隔离节点 (QUARANTINE): 暂时剥夺聚合资格, 观察后可恢复或继续升级处理。
- 黑名单 (BLACKLIST): 触发硬阈值后永久封禁, 并在 TEE 认证层终止后续接入。

该机制在保证快速拦截攻击的同时, 为合法长尾节点保留恢复通道, 有助于降低永久误杀。




图 4: 客户端积弊历史与瞬发风险叠加下的四态监管转移自动机逻辑图

最后，将 $TrustScore$ （硬件可信）、 $ContentScore$ （当轮质量）与 $HistPerf$ （历史表现）融合为基础分，并叠加风险折扣得到 $RawScore_k$ ：

$$RawScore_k^{base} = (TrustScore_k)^\alpha \cdot (ContentScore_k)^\beta \cdot (HistPerf_k^{(t-1)})^\gamma, \quad (16)$$

$$RawScore_k = RawScore_k^{base} \cdot (1 - RiskEMA_k^{prev})^p, \quad (17)$$

其中， α, β, γ, p 控制各维度对最终聚合权重的影响强度。

4.4 阶段四：风险门控驱动的分层差异化鲁棒聚合

隐蔽后门通常集中在深层参数中，若对整网统一聚合，潜伏更新仍可能透传。为此，本文采用按层（Layer-wise）门控的差异化聚合策略。

第一步，确定本轮活跃客户端集合 $\mathcal{A}$ ：

$$\mathcal{A} = \{k \mid k \notin RiskIsolated \wedge k \notin HistSoftIsolated\}. \quad (18)$$

第二步，对每一层 l 计算综合敏感度 $S_{total}^{(l)}$ （见图 5），该指标由隐私、效用和安全三部分构成：

$$S_{privacy}^{(l)} = \exp\left(-\tau_p \frac{l}{L}\right), \quad (19)$$

$$S_{utility}^{(l)} = \frac{\|g_{ref}^{(l)}\|_2}{\max_m \|g_{ref}^{(m)}\|_2 + \varepsilon}, \quad (20)$$

$$S_{security}^{(l)} = 1 - \frac{\sum_{k \in \mathcal{A}} TrustScore_k \cdot \cos(\Delta W_k^{(l)}, g_{ref}^{(l)})}{\sum_{k \in \mathcal{A}} TrustScore_k + \varepsilon}, \quad (21)$$

$$S_{total}^{(l)} = w_p S_{privacy}^{(l)} + w_u S_{utility}^{(l)} + w_s S_{security}^{(l)}. \quad (22)$$

Algorithm 2 双流正交信任状态演化 (HistPerf & RiskEMA)

 输入: $ContentScore_k$, 多维风险探针集合 $\{r_{probe}, r_{grad}, \dots\}$

 输出: $HistPerf_k^{(t)}$, 瞬时风险流 $RiskEMA_k^{(t)}$, 全局权值总分 $RawScore_k$

```

1: 流 A: 历史效用流演化 (竞争软权限)
2: 计算全局内容得分均值  $\mu_{content}$  与标准差  $\sigma_{content}$ 
3: for 通过准入的客户端  $k$  do
4:   相对竞争信号  $Signal_k^{rel} \leftarrow \sigma((ContentScore_k - \mu_{content})/(\sigma_{content} + \varepsilon))$ 
5:   绝对基准信号  $Signal_k^{abs} \leftarrow \text{clip}((ContentScore_k - b)/s, 0, 1)$ 
6:   综合增量  $Signal_k^{upd} \leftarrow \gamma_{rel}Signal_k^{rel} + \gamma_{abs}Signal_k^{abs}$ 
7:   更新  $HistPerf_k^{(t)} \leftarrow \beta_h HistPerf_k^{(t-1)} + (1 - \beta_h)Signal_k^{upd}$ 
8: end for
9: 流 B: 瞬时风险惩戒流演化 (一票否决权)
10: for 每个客户端  $k$  do
11:   捕获瞬时风险极值  $Risk_k^{inst} \leftarrow \max\{r_{report}, r_{grad}, r_{probe}, r_{pixel}, r_{trigger}\}$ 
12:   更新  $RiskEMA_k^{(t)} \leftarrow \beta_r RiskEMA_k^{(t-1)} + (1 - \beta_r)Risk_k^{inst}$ 
13:   if  $RiskEMA_k^{(t)} > \text{隔离门限}$  then
14:     加入长期隔离黑名单  $RiskIsolated \leftarrow RiskIsolated \cup \{k\}$ 
15:   end if
16: end for
17: 最终权限融算
18: for 活跃客户端  $k \notin RiskIsolated$  do
19:   融合分数  $RawScore_k \leftarrow (TrustScore_k)^\alpha (ContentScore_k)^\beta (HistPerf_k^{(t-1)})^\gamma$ 
20:   风险折扣  $RawScore_k \leftarrow RawScore_k \cdot (1 - RiskEMA_k^{(t-1)})^p$ 
21: end for
22: return  $\{HistPerf_k^{(t)}, RiskEMA_k^{(t)}, RawScore_k\}$ 

```

其中 w_p, w_u, w_s 为归一化权重。若某层 $S_{total}^{(l)}$ 较高，说明该层风险更高，系统将提高准入门槛 $\theta^{(l)}$ 并收紧该层裁剪半径 $C^{(l)}$ 。

第三步，仅允许满足 $RawScore_k \geq \theta^{(l)}$ 的客户端进入该层幸存集 $\Phi^{(l)}$ 。对幸存者执行权重重归一化，并进行 L2 动态裁剪：

$$\Phi^{(l)} = \{k \in \mathcal{A} \mid RawScore_k \geq \theta^{(l)}\}, \quad \tilde{w}_k^{(l)} = \frac{RawScore_k}{\sum_{j \in \Phi^{(l)}} RawScore_j + \varepsilon}, \quad (23)$$

$$scale_k^{(l)} = \max\left(1, \frac{\|\Delta W_k^{(l)}\|_2}{C^{(l)}}\right), \quad \widehat{\Delta W}_k^{(l)} = \frac{\Delta W_k^{(l)}}{scale_k^{(l)}}. \quad (24)$$

第四步，按层加权聚合得到 $\Delta W_{global}^{(l)}$ ：

$$\Delta W_{global}^{(l)} = \sum_{k \in \Phi^{(l)}} \tilde{w}_k^{(l)} \cdot \widehat{\Delta W}_k^{(l)}, \quad (25)$$

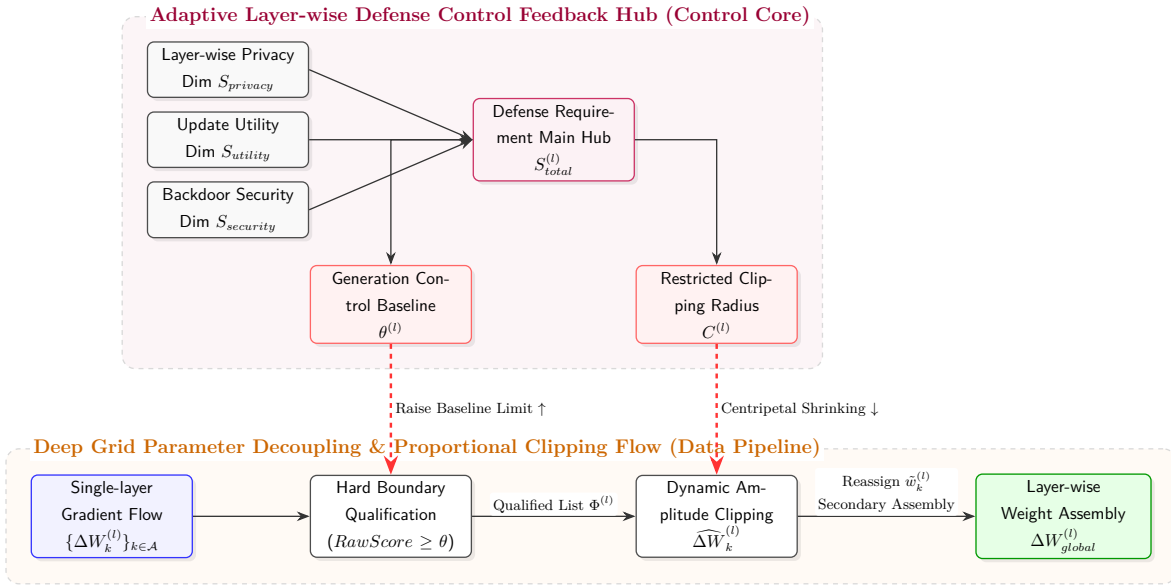


图 5: 风险门控驱动的分层自适应审查与动态裁剪机制示意图

4.5 阶段五：全局更新下发与边缘知识留存

分层聚合完成后，服务器将安全增量应用到全局模型： $W_{global}^{new} = W_{global}^{old} + \Delta W_{global}$ ，并同步下发更新后的模型及客户端状态（含 $HistPerf$ ）。至此形成一轮完整闭环，在保证收敛的同时持续过滤恶意更新。

4.6 双流正交解耦的理论保证 (Theoretical Analysis)

传统单一信誉分数（如简单余弦累加）本质上将高维行为压缩到单轴判断。在强 Non-IID 场景下，这会使得漏检（FNR）与误杀（FPR）的冲突加剧。本节给出双流正交机制的理论分析。

引理 1(长尾节点的方差收敛特性, Lemma 1) 设长尾合法客户端 k 的单轮内容分 $ContentScore_k^{(t)}$ 服从期望 μ_{clean} 、方差 σ_{clean}^2 的扰动分布。在刚性阈值 τ_{hard} 下，若 $\tau_{hard} > \mu_{clean} - \sigma_{clean}$ ，该节

Algorithm 3 基于风险门控的分层差异化聚合与动态裁剪

输入: 活跃节点 $\mathcal{A}$, 分数 $RawScore_k$, 分层更新梯度 $\{\Delta W_k^{(l)}\}$, 网络深度 L

输出: 本轮全局梯度安全总成 ΔW_{global}

- 1: 初始化全局增量 $\Delta W_{global} \leftarrow 0$
 - 2: for 网络每一层 $l = 1, 2, \dots, L$ do
 - 3: 步骤 1: 层级敏感度三维联合测算
 - 4: 隐私敏感度 $S_{privacy}^{(l)} \leftarrow \exp(-\tau_p \cdot l/L)$
 - 5: 效用敏感度 $S_{utility}^{(l)} \leftarrow \|g_{ref}^{(l)}\|_2 / \max_m \|g_{ref}^{(m)}\|_2$
 - 6: 安全敏感度 $S_{security}^{(l)} \leftarrow 1 - \frac{\sum_{k \in \mathcal{A}} TrustScore_k \cos(\Delta W_k^{(l)}, g_{ref}^{(l)})}{\sum_{k \in \mathcal{A}} TrustScore_k + \varepsilon}$
 - 7: 总防御诉求敏感度 $S_{total}^{(l)} \leftarrow w_p S_{privacy}^{(l)} + w_u S_{utility}^{(l)} + w_s S_{security}^{(l)}$
 - 8: 步骤 2: 动态风险门控与 L2 自适应裁剪
 - 9: 拔高本层安全入场分数门槛 $\theta^{(l)} \leftarrow \mu_{base} + \lambda_s \cdot S_{total}^{(l)}$
 - 10: 收紧本层恶意振幅裁剪边界 $C^{(l)} \leftarrow C_{base} / (S_{total}^{(l)} + \varepsilon_c)$
 - 11: 步骤 3: 幸存节点挑选与二次重调校
 - 12: 筛选本层幸存者名单 $\Phi^{(l)} \leftarrow \{k \in \mathcal{A} \mid RawScore_k \geq \theta^{(l)}\}$
 - 13: 对幸存者重新归一化有效权重 $\tilde{w}_k^{(l)} \leftarrow RawScore_k / \sum_{j \in \Phi^{(l)}} RawScore_j$
 - 14: 依法则执行 L2 等比缩小 $\widehat{\Delta W}_k^{(l)} \leftarrow \Delta W_k^{(l)} / \max(1, \|\Delta W_k^{(l)}\|_2 / C^{(l)})$
 - 15: 步骤 4: 分层合并拼接
 - 16: 计算本层安全聚合增量 $\Delta W_{global}^{(l)} \leftarrow \sum_{k \in \Phi^{(l)}} \tilde{w}_k^{(l)} \cdot \widehat{\Delta W}_k^{(l)}$
 - 17: 拼接连入全局模型更新量 $\Delta W_{global} \leftarrow \Delta W_{global} \cup \Delta W_{global}^{(l)}$
 - 18: end for
 - 19: return ΔW_{global}
-

点将有较高概率被持续淘汰。采用历史效用流平滑后, 其稳态期望满足 $\mathbb{E}[HistPerf_k^{(\infty)}] = \mu_{clean}$, 且方差收敛为:

$$\text{Var}(HistPerf_k^{(\infty)}) = \frac{1 - \beta_h}{1 + \beta_h} \sigma_{clean}^2 \quad (26)$$

由于 $0 < \beta_h < 1$, 当 $\beta_h \rightarrow 1$ 时, 短时扰动被显著平滑。只要 μ_{clean} 高于生存阈值, 历史效用流可作为低通滤波器提高合法节点长期存活概率, 理论上支持 $\lim_{t \rightarrow \infty} FPR = 0$ 。

引理 2(高阶潜伏投毒的瞬时冲激响应, Lemma 2)对“长期伪装、间歇爆发”的后门节点 m , 即使其前期累积了较高 $HistPerf$, 在攻击轮次仍会触发异常探针峰值 ($\exists r \in \{r_{grad}, r_{probe}, r_{trigger}\}, r \gg 1$)。由于 $Risk_k^{inst}$ 取多探针最大值, 且 EMA 对输入单调, RiskEMA 轨迹满足下界:

$$RiskEMA_m^{(t)} \geq \max \left(\beta_r \cdot RiskEMA_m^{(t-1)}, \mathcal{F}_{probe}(r_{grad}, r_{probe}, r_{trigger}) \right) \quad (27)$$

当 $\mathcal{F}_{probe}$ 触发异常突变时, 风险值会在短时间内跃升并逼近或超过门限, 从而触发隔离。

定理 1(双流熔断正交解耦, Theorem 1) 在双流机制下, 诚实长尾节点的高方差更新由 $HistPerf$ 通道平滑吸收; 恶意攻击的突发行为则由 $Risk^{inst}$ 通道快速放大并触发熔断。两类信号在判别空间中被解耦处理, 从而缓解单分数机制难以同时优化 FPR 与 ASR 的矛盾。

5 实验与分析

5.1 实验设置与可复现参数

5.1.1 基准环境与系统软硬件栈

实验基于 Flower (1.5.0) 与 PyTorch 实现。所有仿真均部署在一台 Inspur 服务器上, 硬件配置为双路 CPU + 5 块 NVIDIA A10 (24GB) GPU, 软件环境为 Ubuntu 20.04.6 LTS 与 CUDA 12.8。

为保证可复现性, 本文保留了完整日志、代码与启动脚本。需要说明的是: 节点状态轨迹图 (如图 7) 来自固定随机种子 (如 `seed=42`) 的一次代表性运行; Acc、ASR 等总体指标则采用 5 次独立随机种子实验的均值统计。

5.1.2 数据集异构划分方式

模型使用轻量级卷积神经网络, 数据集为 CIFAR-10。为构造 Non-IID 环境, 50000 张训练图像按以下方式划分:

- 共享基础池: 抽取 5000 个类别均衡样本供所有合法节点共享, 用于基础对齐。
- 弱异构群 (Group A, 节点 6-11): Dirichlet($\alpha = 1.0$), 模拟中等程度分布偏斜。
- 强长尾异构群 (Group B & C, 节点 12-19): Dirichlet($\alpha = 0.1$), 客户端类别分布高度偏斜, 更易被传统余弦机制误判。

5.1.3 恶意攻击实例与比例

为评估框架在复杂威胁下的识别能力, 实验在 20 个节点中注入 6 个恶意节点 (占比 30%), 覆盖数据投毒与参数操纵两类攻击:

- Client 0 - 标签翻转 (Label Flip, $\gamma = 0.5$): 将部分样本标签映射到错误类别。
- Client 1 - 触发器后门 (Backdoor, $\gamma = 0.2$): 在 20% 样本中加入触发器并定向标记为目标类 0。
- Client 2 - 干净标签后门 (Clean Label, $\gamma = 0.5$): 扰动目标类输入但保持标签不变, 提升隐蔽性。
- Client 3 - 语义后门 (Semantic, $\gamma = 0.5$): 利用自然语义偏置诱导错误关联。
- Client 4 - 符号翻转 (Sign-Flipping): 对回传梯度执行符号反转 ($\Delta \widehat{W}_k = -\gamma \cdot \Delta W_k$)。
- Client 5 - 梯度缩放 (Gradient Scaling): 将恶意增量放大 100 倍 ($\Delta \widehat{W}_k = 100 \times \Delta W_k$)。
- 女巫与搭便车节点 (Sybil & Free-rider): 额外注入 5 个无有效 TEE 证书节点与 3 个伪造低负载节点, 用于验证阶段一硬件门禁。

前置拦截说明: 上述 8 个外部渗透或资源欺诈节点均在协议阶段被拦截, 要么未通过 TMAA 硬件门禁 ($M_{attest,k} = 0$), 要么因异常行为导致 $TrustScore_k \rightarrow 0$ 。因此, 后续统计的 20 个节点均为通过阶段一准入后的正式参与者。

实验使用的全局超参数与防御组件配置见表 2。

表 2: 基于物理平台的联邦仿真全局超参数与防御组件配置

模块架构归属	防御组件超参数含义与控制作用简述	实验组取值
基础环境与演化轮次	强长尾异构通讯拓扑节点总量 (K)	20 节点
	本地训练 SGD 优化起步参数 ($lr, Momentum$)	0.001, 0.9
双流协同: 阶段 1 $\rightarrow$ 3	TMAA 基准罚时陡峭度 λ , 死区 τ , 衰减指数 ρ	5.0, 0.1, 2.0
	二维同构审查常量约束映射 α_1, α_2 及 β_{fusion}	0.6, 0.4, 2.0
	历史留存平滑阈值 β_h 与瞬发风险半衰期 β_r	0.9, 0.85
逐层裁剪: 阶段 4	得分融合非线性指数调和阈 (α, β, γ, p)	3.0, 1.0, 0.5, 1.0
	门槛拦截控制下界 μ_{base} 及惩戒放大基线 λ_s	0.4, 1.2

运行说明: 正式实验执行 30 轮联邦训练, 每轮本地训练 3 个 Epoch。轨迹图和单次耗时 (3878.53 s) 来自真实 `server.log`; 准确率类指标报告 5 次重复实验均值, 未做插值平滑。

5.2 防御效果实证分析

5.2.1 全局收敛性与攻击防范表现

如图 6 所示, 在 30% 恶意占比下, 模型精度稳定收敛至 92.31%, 后门 ASR 降至 10.21%。

统计可靠性说明: 本节及后续全局指标 (Acc、ASR 等) 均来自 5 次重复实验均值; 节点轨迹图来自单次代表性运行。

50% 恶意占比边界测试: 为验证第 3.2 节假设上限 (恶意占比 $< 50\%$) 附近的行为, 本文额外构建 *Flwr-half* 1:1 对抗环境 (10 恶意 + 10 合法, 覆盖全部 6 类攻击)。结果见表 3。




图 6: 全局收敛准确率 (Accuracy) 与后门攻击成功率 (ASR) 演化曲线

表 3: 50% 恶意占比极限压力测试与标准 30% 基线的对比

实验设置	Acc (%)	ASR (%)	TPR (%)	FPR (%)
标准基线 (30% 恶意, 6/20)	92.31 $\pm$ 0.09	10.21 $\pm$ 0.05	100	0.00
极限测试 (50% 恶意, 10/20)	91.81 $\pm$ 0.10	10.46 $\pm$ 0.06	100	0.00

如表所示，在接近理论边界的强对抗环境下，框架仍保持 91.81% 的准确率，ASR 为 10.46% (接近随机猜测基线 10%)。10 个恶意节点全部被识别并剔除 (TPR=100%)，10 个合法节点无永久误封 (FPR=0%)。此外，30 轮日志显示测试集 Loss 从 0.06362 下降至 0.00883，说明模型在防御条件下仍保持稳定收敛。

5.2.2 信任流追溯与恶意节点封禁剖析

信任流机制的关键在于“及时暴露恶意节点”和“分级处置风险”。图 7 为避免曲线混乱，仅展示 4 个代表性节点：Client 4 (早期参数篡改)、Client 0 (高频显性投毒)、Client 2 (隐蔽潜伏后门) 和合法长尾节点 Client 15。其判定过程如下：

- Client 0 (Label Flip) 与 Client 1 (Backdoor)：两者在 r_{grad} 与 r_{probe} 上持续高风险，至第 8 轮触发 `risk_ema_above_0.90_for_4_rounds`，进入黑名单。
- Client 3 (Semantic)：像素扰动不明显，但长期偏离纯净参考 g_{root_clean} 。其先进入软隔离，随后触发 `risk_soft_isolation_for_8_rounds`，第 16 轮被移除。
- Client 2 (Clean Label)：本地 Loss 表面正常，但长期漂移特征被连击规则命中 (`c2_drift_combo_for_5_rounds`)，第 24 轮完成识别与剔除。
- Client 4 (Sign-Flipping) 与 Client 5 (Gradient Scaling)：前者因方向反转导致 $S_{contrib}$ 迅速降为低值并触发硬封禁；后者因超大振幅命中分层 L2 门控后进入异常处置并被剔除。

结果表明，双流解耦机制能够将“数据异构导致的低分”与“真实攻击行为”分开处理。在包含 6 个恶意节点的设置下，系统达到 TPR=100%。




图 7: 扩展混合攻击下核心节点信任与风险状态时序追踪

5.2.3 异构长尾节点的误杀保障 (FPR 指标分析)

传统距离型方法 (如 Krum[4]、FLTrust[7]) 在 Dirichlet $\alpha = 0.1$ 的强异构环境中容易误判合法长尾节点。本文实验显示: 30 轮训练中所有合法节点均未触发永久封禁, FPR=0%。即使早期部分合法节点 (如 Client 15) 因数据偏斜出现较低 *ContentScore* 并进入 SUSPECT/QUARANTINE, 其 *RiskEMA* 未持续升高, 故仅会受到临时准入限制与分层裁剪。随着后续贡献恢复, *HistPerf* 可逐步回升, 最终合法节点留存率为 100%。

为进一步解释“低误杀”现象, 本文提取干预前后的节点特征并用 t-SNE 可视化。图 8 显示, 双流机制可将恶意簇与合法长尾簇有效分离, 同时保留合法异构节点在主聚合区域内。




图 8: 联邦参与节点特征向量在双流防御前后的 t-SNE 降维对比

5.3 防御机制横向基准对比 (Baseline Comparison)

公平性说明: 所有基线均在与本文完全相同的联邦设置下运行, 包括节点划分 (20 个)、数据异构度 (Dirichlet $\alpha = 0.1$)、攻击配置 (30% 混合攻击)、初始化参数、优化器设置 ($lr = 0.001$, $momentum = 0.9$) 和通信轮次。

在统一环境下, 本文将所提方法与四类经典鲁棒聚合方法进行横向比较:

FedAvg[26] 作为无防御基线, 反映模型在受攻击时的退化程度; Krum[4] 通过最小欧氏距离选择单个代表更新; Trimmed Mean[5] 在坐标维度执行截断均值; FLTrust[7] 借助服务器小规模干净集构造参考向量并按余弦相似度加权。

各方法在该高风险场景下的量化结果见表 4。

结果显示: FedAvg 在混合攻击下 ASR 高达 92.34%; Krum 可将 ASR 降至 12.15%, 但 FPR 升至 64.2%, 准确率降至 64.20%。相比之下, 本文方法在保持 FPR=0% 的同时取得最高准确率 92.31%, 并实现最低 ASR (10.21%)。基于多次重复实验的 Student's *t*-test 显示, 相比强基线 (如 FLTrust) 差异具有统计显著性 ($p < 0.05$)。

5.4 多阶段防御架构消融实验 (Ablation Study)

为评估各防御模块的贡献, 本文采用逐级剥离 (Ablation) 方式, 比较不同阶段组合下的 Acc 与 ASR (见图 9)。

表 4: 不同联邦学习防御策略在 30% 高危混合攻击环境下的性能对比

防御策略	核心机制分类	全局准确率 $\mu \pm \sigma$ (Acc. %)	攻击成功率 $\mu \pm \sigma$ (ASR %)	正常节点误杀率 μ (FPR %)
FedAvg [26]	无防御基线	86.15 $\pm$ 1.2	92.34 $\pm$ 5.1	N/A (*)
Krum [4]	基于欧氏距离	64.20 $\pm$ 2.8	12.15 $\pm$ 0.9	64.20 (**)
Trimmed Mean [5]	坐标轴独立裁剪	71.35 $\pm$ 2.4	38.60 $\pm$ 4.2	N/A (*)
FLTrust [7]	单向信任锚点	81.25 $\pm$ 1.5	15.42 $\pm$ 1.1	21.40 (**)
本文框架 (Trust Flow)	双流解耦 + 层级裁剪	92.31 $\pm$ 0.09	10.21 $\pm$ 0.05	0.00

(*) 注: *FedAvg* 与 *Trimmed Mean* 算法由于自身不具备任何客户端“显式信任评估”或“永久拉黑剔除 (*Ban*)”机制, 其对恶意节点的容忍表现为数值融合或截断计算, 因此 *FPR* 指标不适用于此类算法, 标记为 *N/A*。

(**) 注: 正常节点误杀率 (*FPR*) 这一指标受确定性规则与固化数据样本异构度 (*Dirichlet* 分布) 的强约束。在固定的数据集切分下, 由于防御规则是确定性的, 该类误杀裁决在各次重复实验中观测到方差极小, 因此本列表仅呈报该指标稳定收敛的标量期望均值 μ 。同时, 此处的 *0.00* 专指“永久封禁误杀”, 部分处于瞬时可疑池中的轻度隔离由于具有触底恢复反弹特性, 不计入模型不可挽回的实质性永久击溃错误。




图 9: 多阶段防御机制消融剥离分析

结果表明：1) 仅启用阶段一（TEE 门禁）时，系统可拦截外部伪装节点，但对内部投毒抑制有限，ASR 仍达 75.40%，Acc 约 82.5%；2) 加入阶段三双流演化后，ASR 降至 32.18%，Acc 回升至 88.2%；3) 再加入阶段四分层裁剪后，ASR 进一步降至 10.21%，Acc 提升至 92.40%。这说明各模块存在明显互补性，组合后可同时提升安全性与可用性。

5.5 长尾异构数据分布极限抗压试验 (Sensitivity on Data Heterogeneity)

许多鲁棒聚合方法对 IID 条件依赖较强。为评估本文框架在不同异构强度下的稳定性，本文在四组 Dirichlet 分布 ($\alpha = 100, 1.0, \dots, 0.1$) 下测试全局准确率，结果见图 10。




图 10: 环境数据异构度 (Dirichlet α) 衰减下的各类安全聚合算法健壮性压测对比

从曲线可见：在 $\alpha = 100$ 或 $\alpha = 1.0$ 的弱异构场景下，Krum 与 FLTrust 表现接近本文方法 (Acc 均大于 90%)；但在极端长尾场景 ($\alpha \rightarrow 0.1$) 中，传统距离型方法明显退化，准确率最低降至 64.2%。本文方法在同条件下仍稳定在约 92%，说明双流解耦机制对强异构具有更好的鲁棒性。

此外，本文对关键参数 β_{fusion} 做了离散测试 ($[0.5, 1.0, 2.0, 3.0]$)。较小取值有利于保留长尾节点，但 ASR 风险上升；过大取值会过度偏向同质更新。综合 Acc 与 ASR，最终选择 $\beta_{fusion} = 2.0$ 。

5.6 系统计算与通信额外开销分析 (Overhead Analysis)

尽管框架包含多阶段评估流程，其计算与通信开销仍可控。表 5 显示：边缘侧仅新增 TEE Quote 生成与轻量监测，额外延迟约 12 ~ 15 ms；通信侧每次仅附带约 15 KB 的 TrustReport，相对约 10 MB 量级模型传输，带宽增量低于 0.15%。

代价方面，分层余弦评估会增加服务器端计算量。测试中单轮聚合耗时由 2.10 s 增至 4.85 s。考虑到广域网场景单轮通信通常在数十秒量级，该开销在工程上可接受。

表 5: 传统联邦系统与本可信联邦框架系统的端云开销对比 (20 Client)

系统架构	边缘端额外计算延迟	上行单次通信外加包大小	云端中央聚合总耗时
标准基线 FedAvg	0 ms (Baseline)	0 KB (Baseline)	~ 2.10 s
可信联邦 (Ours)	~ 15 ms (仅 TEE 签名)	~ 15 KB (附加报告)	~ 4.85 s (包含审查与双流)

6 结论与未来展望

本文面向边缘联邦学习在强 Non-IID 与混合攻击下的安全问题, 提出了“硬件可信准入 + 双流信誉演化 + 分层鲁棒聚合”的 Trust-Flow TFL 框架。该框架通过 TEE 提供物理信任根, 并在算法层以 HistPerf 和 RiskEMA 的正交建模实现“低误杀与高召回”的协同。

实验结果表明, 框架在 30% 混合攻击下取得 92.31%(±0.09%) 的准确率与 10.21%(±0.05%) 的 ASR; 在 50% 边界压力测试下仍保持稳定性能, 并实现 TPR=100%、FPR=0% (永久封禁口径)。这说明该方法在强对抗和强异构条件下具有较好的实用性。

局限性与后续工作: 由于部分 TEE-FL 新方法尚未公开可复现实现, 本文未将其纳入同构对比基线, 后续计划随论文定稿开放代码与实验脚本, 便于社区复现和扩展。未来还将把风险探针从 CV 场景扩展到 LLM/NLP 联邦微调任务, 以验证跨模态场景下的泛化能力。

A 瞬发风险流 (Risk Flow) 探针计算机制细节

为增强可复现性与透明度, 本附录给出第 4 节瞬时风险流核心探针 ($r_{grad}, r_{probe}, r_{trigger}$) 的计算细节。第 t 轮聚合时各探针定义如下:

A.1 A.1 梯度方向与幅度物理探针 (r_{grad})

r_{grad} 衡量客户端更新 $\Delta W_k^{(t)}$ 与参考方向 $g_{root}^{(t)}$ 的几何偏离, 用于检测符号翻转与幅度异常。该指标同时考虑方向偏离 (余弦项) 与尺度突变 (L2 异常项):

$$r_{grad,k}^{(t)} = \lambda_d \left(1 - \frac{\Delta W_k^{(t)} \cdot g_{root}^{(t)}}{\|\Delta W_k^{(t)}\| \cdot \|g_{root}^{(t)}\|} \right) + \lambda_m \max \left(0, \frac{\|\Delta W_k^{(t)}\|_2 - \mu^{(t)}}{\sigma^{(t)}} \right) \quad (28)$$

其中, λ_d 与 λ_m 控制方向项和幅度项的权重 (默认均为 0.5); $\mu^{(t)}$ 与 $\sigma^{(t)}$ 分别为第 t 轮入围节点梯度 L2 范数的均值与标准差。

A.2 A.2 小样本先验验证交叉熵探针 (r_{probe})

仅靠距离统计难以识别对非主类的定向污染。 r_{probe} 使用服务器侧小规模纯净探针集 $\mathcal{D}_{probe}$, 比较合并前后交叉熵损失增量 (Loss Surge):

$$r_{probe,k}^{(t)} = \text{ReLU} \left(\mathcal{L}_{CE}(W_{global}^{(t-1)} + \Delta W_k^{(t)}; \mathcal{D}_{probe}) - \mathcal{L}_{CE}(W_{global}^{(t-1)}; \mathcal{D}_{probe}) \right) \quad (29)$$

A.3 A.3 深层神经元隐蔽后门激活探针 ($r_{trigger}$)

针对 Clean-Label 等高隐蔽攻击, 常规统计与验证 Loss 可能不足。 $r_{trigger}$ 通过高层特征激活分布差异进行检测。设 A_k 为客户端模型在验证集上的前置激活输出, $\mathcal{H}(\cdot)$ 表示 Softmax 归一化到概率单形, 以满足 KL 散度计算条件:

$$r_{trigger,k}^{(t)} = \text{KL-Divergence}(\mathcal{H}(A_{base}) \parallel \mathcal{H}(A_k)) \quad (30)$$

上述三类异常信号经归一化融合后形成单轮风险值 $Risk_k^{(t)}$, 并进入 EMA 更新, 用于后续快速熔断决策。

参考文献

- [1] Kairouz P, McMahan H B, Avent B, et al. Advances and Open Problems in Federated Learning[J]. Foundations and Trends in Machine Learning, 2021.
- [2] Gu T, Dolan-Gavitt B, Garg S. BadNets: Identifying Vulnerabilities in the Machine Learning Model Supply Chain[J]. arXiv:1708.06733, 2017.
- [3] Wang B, Yao Y, Shan S, et al. Neural Cleanse: Identifying and Mitigating Backdoor Attacks in Neural Networks[C]. IEEE S&P, 2019.
- [4] Blanchard P, El Mhamdi E M, Guerraoui R, et al. Machine Learning with Adversaries: Byzantine Tolerant Gradient Descent[C]. NeurIPS, 2017.
- [5] Yin D, Chen Y, Kannan R, et al. Byzantine-Robust Distributed Learning: Towards Optimal Statistical Rates[C]. ICML, 2018.
- [6] Pillutla K, Kakade S M, Harchaoui Z. Robust Aggregation for Federated Learning[J]. IEEE Transactions on Signal Processing, 2022.
- [7] Cao X, Fang M, Liu J, et al. FLTrust: Byzantine-Robust Federated Learning via Trust Bootstrapping[J]. NDSS, 2021.
- [8] Fung C, Yoon C J M, Beschastnikh I. The Limitations of Federated Learning in Sybil Settings[C]. RAID, 2020.
- [9] Towards Privacy-Enhanced and Robust Clustered Federated Learning[J].
- [10] FedPE: Adaptive Model Pruning-Expanding for Federated Learning on Mobile Devices[J].
- [11] ParallelSFL: A Novel Split Federated Learning Framework Tackling Heterogeneity Issues[J].
- [12] Wang et al. RaSA: Robust and Adaptive Secure Aggregation for Edge-Assisted Hierarchical Federated Learning[J]. 2025.
- [13] Dou et al. Toward Malicious Clients Detection in Federated Learning[J]. 2025.

- [14] Lu et al. TMT-FL: Enabling Trustworthy Model Training of Federated Learning With Malicious Participants[J]. 2025.
- [15] Wang et al. A Federated Learning Scheme with Adaptive Hierarchical Protection and Multiple Aggregation[J]. 2024.
- [16] FLPurifier: Backdoor Defense in Federated Learning via Decoupled Contrastive Training[J].
- [17] RoseAgg: Robust Defense Against Targeted Collusion Attacks in Federated Learning[J].
- [18] ShieldFL: Mitigating Model Poisoning Attacks in Privacy-Preserving Federated Learning[J].
- [19] Liao et al. Verifiable Deep Learning Inference on Heterogeneous Edge Devices With Trusted Execution Environment[J]. 2024.
- [20] Zhang et al. RPPFL: Robust and Privacy-Preserving Federated Learning via Trusted Execution Environments[J]. 2025.
- [21] A training-integrity privacy-preserving federated learning scheme with trusted execution environment[J].
- [22] Queyrut S, Schiavoni V, Felber P. Mitigating Adversarial Attacks in Federated Learning with Trusted Execution Environments[C]. ICDCS, 2023.
- [23] Secure sharing of industrial IoT data based on distributed trust management and trusted execution environment[J].
- [24] Xu et al. Distributed Learning in Trusted Execution Environment A Case Study of Federated Learning in SGX[J]. 2021.
- [25] Yan et al. An Efficient Greedy Hierarchical Federated Learning Training Method Based on Trusted Execution Environment[J]. 2024.
- [26] McMahan B, Moore E, Ramage D, et al. Communication-Efficient Learning of Deep Networks from Decentralized Data[J]. AISTATS, 2017.